Detección automática de fracturas cervicales en tomografía computarizada

Construcción, evaluación y comparación de modelos de aprendizaje profundo

Proyecto 2 — Fase de resultados · Reto 20 CC3084 · Data Science · Universidad del Valle de Guatemala · Semestre II 2026

Conjunto de datos	RSNA 2022 Cervical Spine Fracture Detection
Repositorio	https://github.com/rodrigoajmac/CC3084_Proyecto_2
Aplicación	Streamlit — carpeta `Aplicacion/`

1. Introducción

1.1 Contenido del informe

Este informe documenta la segunda fase del Proyecto 2. La primera fase produjo un análisis exploratorio del conjunto RSNA 2022 Cervical Spine Fracture Detection; esta segunda fase parte de aquellos hallazgos para **construir, ajustar, evaluar y comparar modelos de aprendizaje automático**, y para exponerlos en una aplicación interactiva que permite clasificar imágenes nuevas.

El documento se organiza así: la sección 2 fija los objetivos; la sección 3 reúne el marco teórico de procesamiento de imagen médica y de los algoritmos empleados; la sección 4 describe la metodología, incluyendo la partición de datos y la justificación de cada elección; la sección 5 presenta los resultados, su análisis comparativo y la aplicación construida; la sección 6 cierra con las conclusiones.

1.2 Problema a resolver

La fractura de la columna cervical es una lesión de baja prevalencia y alta consecuencia. Más de un millón de pacientes son evaluados cada año en Estados Unidos por sospecha de lesión cervical, y en adultos la tomografía computarizada ha desplazado casi por completo a la radiografía simple como estudio de elección (Minja et al., 2018). Entre el 10 % y el 11 % de las fracturas cervicales derivan en lesión de la médula espinal (Fredø et al., 2014), de modo que un diagnóstico tardío puede traducirse en deterioro neurológico irreversible.

La dificultad no es solo clínica sino computacional. El análisis exploratorio de la fase anterior estableció tres hechos que condicionan cualquier solución:

1. **La lesión es diminuta en relación con la imagen.** La región delimitada por las anotaciones ocupa una mediana del 2.415 % de un corte de 512 × 512 píxeles, una relación fondo-a-lesión cercana a 41 : 1.
2. **La supervisión espacial es escasa.** Solo el 11.64 % de los estudios tiene *bounding box* y el 4.31 % tiene segmentación vertebral; tres de cada cuatro casos positivos carecen de localización.

3. **Existe un riesgo real de atajo.** Las variables de adquisición difieren de forma estadísticamente significativa entre clases (`n_slices`, $p = 1.82 \times 10^{-8}$), de modo que un modelo puede aprender a reconocer el protocolo del hospital en lugar de la lesión.

El problema que resuelve esta fase se enuncia así:

> **¿Es posible entrenar un clasificador que, a partir de un corte axial de tomografía cervical, identifique la presencia de una fractura visible con una sensibilidad y especificidad útiles, sin que su desempeño se explique por atajos de adquisición ni por fuga de información entre pacientes?**

---

2. Objetivos

2.1 Objetivo general

Construir, ajustar y comparar modelos de aprendizaje profundo capaces de clasificar la presencia de fractura cervical visible en cortes axiales de tomografía computarizada, y exponerlos en una aplicación interactiva que permita explorar los datos, ejecutar la clasificación sobre imágenes nuevas y comparar el rendimiento de cada algoritmo.

2.2 Objetivos específicos

1. **Revisar la literatura indexada** sobre arquitecturas de aprendizaje profundo aplicadas a la detección de fracturas en imagen médica, y seleccionar a partir de ella los algoritmos a implementar.
2. **Construir un conjunto supervisado a nivel de corte** a partir de la anotación espacial disponible, con una definición de clases explícita y auditable que evite etiquetar cortes cuya condición real se desconoce.
3. **Entrenar al menos tres modelos** de capacidad creciente —una red convolucional propia y dos arquitecturas preentrenadas— y ajustar sus hiperparámetros.
4. **Evaluar y comparar los modelos** con métricas adecuadas a un problema de clasificación binaria desbalanceada en contexto clínico (sensibilidad, especificidad, F1 y ROC-AUC), sobre una partición agrupada por paciente que impida la fuga de información.
5. **Desarrollar una aplicación interactiva** que permita explorar las variables del conjunto, clasificar imágenes nuevas con cada modelo por separado o con todos a la vez, y mostrar u ocultar el rendimiento de cada algoritmo.

---

3. Marco teórico

3.1 Procesamiento de imágenes

3.1.1 La imagen digital y la imagen médica

Una imagen digital es una matriz de valores de intensidad muestreados espacialmente. En fotografía convencional esos valores son adimensionales y se codifican típicamente en 8 bits por canal. En tomografía computarizada, en cambio, el valor de cada píxel tiene **significado físico**: expresa el coeficiente de atenuación lineal del tejido normalizado respecto del agua, en **unidades Hounsfield (HU)**, según

$$\text{HU} = 1000 \times \frac{\mu_{\text{tejido}} - \mu_{\text{agua}}}{\mu_{\text{agua}} - \mu_{\text{aire}}}$$

Por convención el agua vale 0 HU y el aire −1000 HU. El hueso cortical alcanza valores superiores a +1000 HU. Los archivos DICOM no almacenan HU directamente sino enteros que deben transformarse con dos atributos de la cabecera:

$$\text{HU} = \text{pixel_array} \times \text{RescaleSlope} + \text{RescaleIntercept}$$

Omitir esta conversión produce imágenes cuyos valores no son comparables entre estudios de distintos equipos, un error silencioso porque la imagen sigue viéndose plausible.

3.1.2 Ventaneo radiológico

El rango útil en TC abarca unas 4000 HU, mientras que un monitor y la mayoría de las arquitecturas de red trabajan sobre 256 niveles. La **ventana radiológica** resuelve esa compresión mapeando linealmente un intervalo de interés al rango visible, y descartando lo que queda fuera. Dados un centro C y un ancho A:

$$I(x) = \text{clip}\left(\frac{x - (C - A/2)}{A},\ 0,\ 1\right)$$

La elección de la ventana no es estética sino determinante: la **ventana ósea** (C = 400, A = 1800) conserva el contraste entre hueso cortical y trabecular, que es donde se manifiesta una línea de fractura, mientras que la ventana de tejido blando (C = 40, A = 400) satura el hueso por completo. Un modelo alimentado con la ventana incorrecta nunca verá la señal que debe aprender.

3.1.3 Remuestreo y normalización geométrica

Las tomografías no son isotrópicas: el espaciado entre píxeles dentro del corte difiere del espaciado entre cortes, y ambos varían entre equipos. En el conjunto estudiado el `pixel_spacing` toma 324 valores distintos entre 0.190 y 0.713 mm. Para que una distancia en píxeles signifique lo mismo en todos los estudios es necesario **remuestrear a espaciado isotrópico**, típicamente 1 × 1 × 1 mm.

3.1.4 Aumento de datos

El aumento de datos aplica transformaciones que preservan la etiqueta —rotaciones pequeñas, traslaciones, zoom, reflexión— para ampliar artificialmente la variabilidad del conjunto de entrenamiento y reducir el sobreajuste (Shorten & Khoshgoftaar, 2019). En imagen médica la elección de transformaciones

debe respetar la anatomía: una reflexión horizontal es admisible en una estructura aproximadamente simétrica como la columna en corte axial, mientras que rotaciones grandes producirían configuraciones anatómicamente imposibles.

3.2 Análisis de imagen desde el punto de vista médico

3.2.1 Anatomía de la columna cervical

La columna cervical consta de siete vértebras, C1 a C7. Las dos primeras son atípicas: **C1 (atlas)** carece de cuerpo vertebral y forma un anillo que sostiene el cráneo, y **C2 (axis)** posee la apófisis odontoides, un pivote óseo que permite la rotación de la cabeza. De C3 a C7 las vértebras son morfológicamente similares, con cuerpo vertebral anterior, arco posterior y apófisis.

Esta heterogeneidad anatómica importa para el modelado: un corte axial a la altura de C1 no se parece a un corte a la altura de C6, de modo que un clasificador por corte debe aprender a reconocer discontinuidad ósea en contextos anatómicos muy distintos.

3.2.2 Distribución y mecanismos de la fractura cervical

Las fracturas cervicales no se distribuyen de manera uniforme. Goldberg et al. (2001) documentaron, en un estudio multicéntrico de 21 instituciones, que C2, C6 y C7 concentran el 63.3 % de las lesiones. El análisis exploratorio de este proyecto reprodujo ese patrón de forma independiente: C2, C6 y C7 reúnen el **66.14 %** de los niveles fracturados, y C7 resulta el nivel más frecuente con 393 casos. Esta concordancia es una validación externa de que la muestra no está sesgada hacia un patrón atípico.

La bimodalidad obedece a la biomecánica: las lesiones de la unión craneocervical (C1–C2) responden a mecanismos de hiperextensión y carga axial, mientras que la unión cervicotorácica (C6–C7) concentra tensión por ser la transición entre un segmento móvil y uno rígido.

3.2.3 Por qué la interpretación es difícil

La detección es un problema genuinamente difícil incluso para el radiólogo. En población mayor, la enfermedad degenerativa y la osteoporosis producen irregularidades corticales que imitan o enmascaran líneas de fractura. A esto se suma que la lesión puede ser visible en apenas unos pocos cortes de un volumen de varios cientos, y que la evaluación de la alineación cervical requiere la reconstrucción sagital, no el plano axial original.

3.2.4 El problema de la generalización

Voter et al. (2021) evaluaron un algoritmo comercial aprobado para detección de fracturas cervicales y encontraron que su precisión diagnóstica caía de forma marcada al aplicarse a datos externos a los de su entrenamiento. Este resultado es el que motiva la existencia misma del conjunto RSNA 2022, construido deliberadamente con 12 instituciones de 9 países en 6 continentes (Lin et al., 2023) para que los modelos entrenados sobre él enfrenten desde el inicio la variabilidad que rompe a los modelos monocéntricos.

3.3 Algoritmos de aprendizaje automático

3.3.1 Redes neuronales convolucionales

La red neuronal convolucional (CNN) es la arquitectura de referencia en visión por computadora. Su operación central es la convolución discreta de un núcleo aprendido sobre la entrada, lo que le confiere dos propiedades decisivas frente a una red densa: **compartición de parámetros** (el mismo núcleo se aplica en toda la imagen, reduciendo drásticamente el número de pesos) y **equivarianza a la traslación** (una característica se detecta sin importar dónde aparezca). Ambas son especialmente pertinentes aquí, donde la fractura puede aparecer en cualquier posición del corte.

Litjens et al. (2017), en una revisión de más de 300 trabajos, documentan que las CNN se convirtieron en el método dominante en análisis de imagen médica, desplazando a los enfoques basados en características diseñadas a mano.

3.3.2 Redes residuales

Al aumentar la profundidad, las redes convolucionales clásicas sufren degradación: el error de entrenamiento crece en lugar de disminuir. He et al. (2016) atribuyeron el fenómeno a la dificultad de optimizar transformaciones identidad y propusieron la **conexión residual**, que reformula cada bloque como $\mathcal{F}(x) + x$. Esto permite que el gradiente fluya sin atenuarse por la ruta identidad y habilitó entrenar redes de cientos de capas. La idea es hoy un componente estándar de prácticamente toda arquitectura moderna.

3.3.3 Arquitecturas eficientes: MobileNetV2 y EfficientNet

MobileNetV2 (Sandler et al., 2018) sustituye la convolución estándar por la **convolución separable en profundidad**, que factoriza la operación en un filtrado por canal seguido de una combinación lineal punto a punto. El costo cae aproximadamente en un factor igual al número de canales de salida, con pérdida de precisión modesta. Añade además los *bloques residuales invertidos* con cuello de botella lineal.

EfficientNet (Tan & Le, 2019) parte de observar que el escalado de redes se hacía de forma arbitraria en una sola dimensión —profundidad, anchura o resolución— y propone el **escalado compuesto**, que las ajusta conjuntamente con coeficientes derivados de una búsqueda. EfficientNetB0, la variante base, alcanza precisión competitiva con un orden de magnitud menos de parámetros que arquitecturas anteriores de rendimiento similar.

3.3.4 Aprendizaje por transferencia

Entrenar una red profunda desde cero exige volúmenes de datos de los que rara vez se dispone en imagen médica. El **aprendizaje por transferencia** reutiliza los pesos de una red preentrenada sobre un corpus grande —habitualmente ImageNet (Deng et al., 2009)— y readapta las capas finales a la tarea nueva. La justificación es que las primeras capas aprenden detectores de bordes, texturas y gradientes que son genéricos y transfieren bien incluso a dominios visualmente distintos como la radiología.

El procedimiento habitual tiene dos etapas: primero se **congela** la base preentrenada y se entrena solo la cabeza de clasificación con una tasa de aprendizaje normal; después se **descongela** la base y se continúa con una tasa de aprendizaje uno o dos órdenes de magnitud menor, para refinar las características sin destruir lo aprendido.

3.3.5 Aprendizaje por atajos

Geirhos et al. (2020) describen el fenómeno del **shortcut learning**: las redes profundas tienden a explotar correlaciones superficiales presentes en el conjunto de entrenamiento que predicen bien la etiqueta pero no corresponden al concepto que se pretende aprender, y que por tanto no sobreviven al cambio de distribución. En imagen médica el riesgo es agudo y documentado: modelos que aprenden a reconocer el equipo, el hospital o incluso marcadores físicos sobre la placa.

Este marco es directamente aplicable aquí. El análisis exploratorio detectó que las variables de adquisición difieren significativamente entre clases, y la sección 4 describe las decisiones de diseño adoptadas específicamente para neutralizar ese riesgo.

3.3.6 Métricas de evaluación en contexto clínico

Para un clasificador binario con matriz de confusión de verdaderos y falsos positivos y negativos (VP, FP, VN, FN):

Métrica	Fórmula	Lectura clínica
Sensibilidad (recall)	VP / (VP + FN)	proporción de fracturas detectadas
Especificidad	VN / (VN + FP)	proporción de sanos correctamente descartados
Precisión	VP / (VP + FP)	de lo marcado como fractura, cuánto lo era
F1	media armónica de precisión y recall	equilibrio entre ambas
ROC-AUC	área bajo la curva sensibilidad vs. 1 − especificidad	capacidad de ordenamiento, independiente del umbral

En cribado de patología grave la **sensibilidad domina**: un falso negativo es una fractura no diagnosticada, con riesgo de deterioro neurológico, mientras que un falso positivo produce una revisión adicional. Por eso la exactitud global es una métrica inadecuada y el umbral de decisión no tiene por qué ser 0.5.

Saito y Rehmsmeier (2015) advierten además que, con clases muy desbalanceadas, la curva ROC puede dar una impresión excesivamente optimista y la curva de precisión-recall resulta más informativa. En el diseño de este trabajo las clases se construyeron balanceadas (sección 4.2), lo que mantiene la ROC interpretable.

---

4. Metodología

4.1 Pasos seguidos

1. **Revisión bibliográfica** de arquitecturas aplicadas a detección de fracturas en imagen médica (sección 3).
2. **Definición de la tarea supervisada** a partir de la anotación espacial disponible.
3. **Construcción del conjunto** de cortes con sus etiquetas, leyendo los DICOM, aplicando la conversión a HU y la ventana ósea.
4. **Partición agrupada por paciente** en entrenamiento, validación y prueba.
5. **Entrenamiento** de tres arquitecturas, con ajuste de hiperparámetros sobre validación.

6. **Evaluación** sobre la partición de prueba, nunca vista durante el entrenamiento.
7. **Comparación** de los modelos por efectividad, coste de entrenamiento y latencia.
8. **Integración** de los modelos en la aplicación Streamlit.

4.2 Definición de la tarea y construcción de las etiquetas

El conjunto RSNA etiqueta **estudios completos**, no cortes individuales. Como la aplicación recibe una imagen 2D, fue necesario derivar una tarea a nivel de corte. La derivación se apoyó en `train_bounding_boxes.csv`:

Clase	Origen	Criterio
Positivo	7 217 cortes con *bounding box*	la lesión es visible en ese corte
Negativo fácil	estudios con `patient_overall = 0`	ninguna vértebra fracturada
Negativo difícil	estudios positivos, cortes a más de 20 de distancia de toda caja	hueso sano del mismo paciente

Tres decisiones merecen justificación explícita:

Los estudios positivos sin caja se excluyen por completo. De ellos se sabe que contienen una fractura, pero no en qué corte. Etiquetar sus cortes como positivos introduciría ruido masivo —la mayoría no muestra la lesión— y etiquetarlos como negativos sería directamente falso. Excluirlos cuesta datos pero preserva la integridad de la etiqueta.

Se incluyen negativos difíciles del mismo paciente. Si todos los negativos provinieran de pacientes sanos, la red podría separar las clases reconociendo al paciente o su protocolo de adquisición, sin mirar nunca el hueso. Tomar cortes sanos **del mismo estudio positivo** hace que ese atajo deje de funcionar: el paciente, el equipo y el protocolo son idénticos a ambos lados de la etiqueta. Es la respuesta de diseño directa al riesgo de *shortcut learning* que documentó el análisis exploratorio.

Los negativos fáciles se muestrean en las mismas posiciones relativas que los positivos. El análisis exploratorio mostró que las cajas se concentran alrededor de la posición relativa 0.543 de la pila. Muestrear negativos uniformemente habría dejado la posición dentro del volumen como pista espuria.

4.3 Selección de los conjuntos de entrenamiento y prueba

La partición es **70 % / 15 % / 15 %** para entrenamiento, validación y prueba, pero el detalle decisivo no es la proporción sino la unidad de agrupamiento:

> La partición se hace por `StudyInstanceUID` mediante `GroupShuffleSplit`, de modo que **ningún corte de un mismo paciente puede aparecer en dos particiones a la vez**.

La razón es concreta y se desprende del análisis exploratorio. Los cortes contiguos de un mismo estudio son casi idénticos: con un grosor mediano de 0.625 mm, dos cortes vecinos muestran prácticamente la misma anatomía. Una partición aleatoria a nivel de corte colocaría imágenes casi duplicadas a ambos lados, y el modelo obtendría una métrica de prueba excelente por haber memorizado al paciente. El agrupamiento se verifica programáticamente con una aserción que falla si existe cualquier estudio compartido entre particiones.

La validación se usa exclusivamente para la parada temprana y el ajuste de hiperparámetros; la partición de prueba se reserva y se evalúa una sola vez.

4.4 Selección de los algoritmos y sus razones

Se eligieron tres arquitecturas de **capacidad creciente**, de modo que la comparación sea informativa y no un simple ranking:

Modelo	Parámetros	Razón de la elección
CNN propia	~0.3 M, desde cero	Línea base honesta. Sin ella no se puede afirmar cuánto aporta realmente la transferencia.
MobileNetV2	~2.3 M, ImageNet	Transferencia ligera; convoluciones separables la hacen la más rápida en inferencia, lo que importa para la aplicación interactiva (Sandler et al., 2018).
EfficientNetB0	~4.0 M, ImageNet	Mayor capacidad con escalado compuesto; permite comprobar si más parámetros ayudan con este volumen de datos (Tan & Le, 2019).

El criterio de diseño es que la comparación responda una pregunta real: **si las dos redes preentrenadas no superan claramente a la CNN pequeña, el cuello de botella son los datos y no la capacidad del modelo** — una conclusión más útil que saber cuál arquitectura gana por unas centésimas.

Las dos redes preentrenadas esperan tres canales, así que el corte en escala de grises se replica. Cada una aplica además su propia función `preprocess_input` oficial, incorporada **dentro del grafo del modelo**. Esta decisión es deliberada: el artefacto exportado contiene su propio preprocesamiento, de modo que la aplicación declara `normalization: none` y resulta imposible que normalice dos veces.

4.5 Ajuste de hiperparámetros

Hiperparámetro	Valor	Justificación
Resolución	224 × 224	Resolución nativa de los pesos ImageNet; evita interpolar los filtros aprendidos.
Tamaño de lote	64	Equilibrio entre estabilidad del gradiente y memoria de GPU.
Optimizador	Adam	Convergencia robusta sin ajuste fino de la tasa.
Tasa, etapa 1	1×10^{-3}	Entrenar la cabeza desde inicialización aleatoria.
Tasa, etapa 2	1×10^{-5}	Cien veces menor para refinar la base sin destruir los pesos preentrenados.
Parada temprana	`val_auc` , paciencia 3	Restaura los mejores pesos; evita fijar un número de épocas arbitrario.
Aumento	reflexión, rotación ±4 %, zoom 8 %, traslación 5 %	Transformaciones anatómicamente plausibles en corte axial.

El criterio de parada vigila **AUC de validación** y no la pérdida, porque es la métrica que mide capacidad de ordenamiento con independencia del umbral.

4.6 Herramientas utilizadas

Recursos de cómputo

El conjunto completo ocupa unos 350 GB en aproximadamente 700 000 archivos DICOM, lo que descarta el trabajo local. Todo el procesamiento de imagen y el entrenamiento se ejecutaron en **Kaggle Notebooks**, donde el conjunto se monta como sistema de archivos de solo lectura, con acelerador **GPU**. La redacción, las figuras derivadas y la aplicación se desarrollaron localmente.

Lenguajes, bibliotecas y paquetes

Herramienta	Uso
Python ≥ 3.10	Lenguaje base del proyecto.
TensorFlow / Keras	Definición, entrenamiento y exportación de los modelos.
scikit-learn	Partición agrupada y cálculo de métricas.
pydicom	Lectura de cabeceras y píxeles DICOM.
NumPy / pandas	Manipulación numérica y tabular.
Matplotlib / seaborn	Figuras estáticas del informe.
Streamlit	Aplicación interactiva.
Plotly	Gráficas interactivas dentro de la aplicación.
PyYAML	Configuración declarativa de los modelos en la aplicación.
Git / GitHub	Versionado y evaluación de contribuciones individuales.

---

5. Resultados y análisis de resultados

5.1 Características del conjunto de datos original

El conjunto RSNA 2022 contiene **2 019 estudios** de tomografía computarizada en el conjunto de entrenamiento, cada uno un volumen tridimensional de entre 69 y 1 082 cortes axiales en formato DICOM, con un total aproximado de 700 000 archivos y 350 GB. Las etiquetas son ocho variables binarias por estudio: `patient_overall` y `C1` a `C7`.

De los 2 019 estudios, **961 (47.60 %) presentan fractura**. A nivel vertebral se registran 1 444 niveles fracturados, concentrados en C7 (393), C2 (285) y C6 (277); estos tres niveles reúnen el 66.14 % del total, en línea con el 63.3 % que reporta la literatura multicéntrica (Goldberg et al., 2001).

La anotación espacial es escasa: 7 217 *bounding boxes* sobre 235 estudios (11.64 %) y 87 segmentaciones vertebrales (4.31 %).

5.2 Tareas de limpieza y preprocesamiento

Las operaciones aplicadas se derivan de los hallazgos del análisis exploratorio, no de una lista genérica:

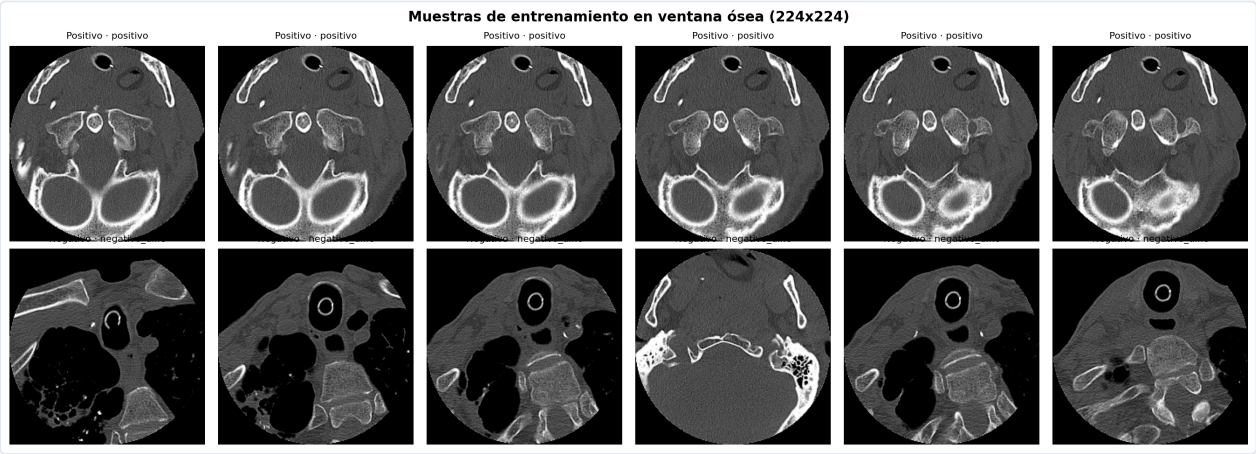
#	Operación	Hallazgo que la motiva
1	Conversión a unidades Hounsfield con `RescaleSlope` / `RescaleIntercept`	Los píxeles crudos no son comparables entre equipos.
2	Ventana ósea (C = 400, A = 1800) y recorte a [0, 1]	Sin ventana el hueso trabecular pierde el contraste donde aparece la fractura.
3	Redimensionado bilineal a 224 × 224	Resolución nativa de los pesos ImageNet.
4	Ordenamiento por `ImagePositionPatient[2]`, nunca por nombre de archivo	El 90.24 % de los estudios apila el eje z en sentido descendente.
5	Instalación del decodificador JPEG Lossless (`pylibjpeg`)	Sin él, una fracción grande de los DICOM comprimidos falla al leerse **en silencio**.
6	Exclusión de estudios positivos sin *bounding box*	Se sabe que hay fractura pero no en qué corte: ninguna etiqueta por corte sería fiable.
7	Partición agrupada por `StudyInstanceUID`	Cortes contiguos son casi idénticos; sin agrupar, la métrica de prueba se infla.

La operación 5 merece énfasis porque fue un defecto real detectado durante el desarrollo: una primera ejecución perdió el 35 % de los cortes sin lanzar ningún error, simplemente porque faltaba el decodificador. El notebook ahora **aborta** si la tasa de fallos de lectura supera el 5 %, en lugar de entrenar con un conjunto mutilado.

5.3 Composición del conjunto de modelado

Tipo de corte	Cortes	Proporción
positivo	7,217	50.1 %
negativo_facil	3,628	25.2 %
negativo_dificil	3,557	24.7 %

La inclusión de **negativos difíciles** —cortes de hueso sano tomados de los mismos pacientes que aportan los positivos— es la decisión de diseño central. Sin ellos, la red podría separar las clases reconociendo al paciente o su protocolo de adquisición, un riesgo que el análisis exploratorio había cuantificado (`n_slices` , $p = 1.82 \times 10^{-8}$). Con ellos, el paciente y el equipo son idénticos a ambos lados de la etiqueta y ese atajo deja de pagar.

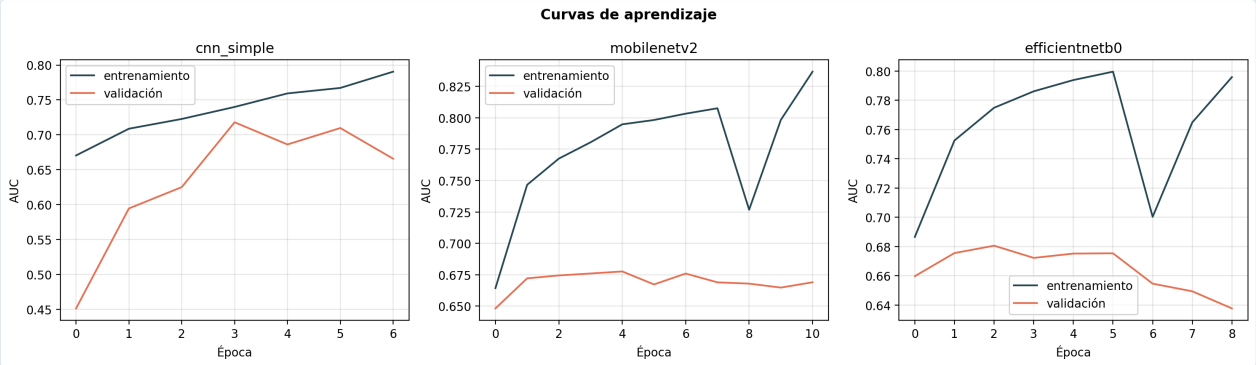


Interpretación. La fila superior muestra cortes con fractura anotada y la inferior cortes negativos, todos en ventana ósea a 224 × 224. La comparación visual confirma lo que anticipaba el análisis exploratorio: a esta escala la diferencia entre ambas filas **no es evidente a simple vista**, lo que sitúa la dificultad real de la tarea y explica por qué ninguna métrica se acerca a la perfección.

5.4 Ajuste de hiperparámetros

El entrenamiento de las dos redes preentrenadas se hizo en dos etapas: primero con la base congelada y tasa 1×10^{-3} para ajustar solo la cabeza, después descongelando la base con tasa 1×10^{-5}. El salto de cien veces es deliberado: con la tasa alta, los gradientes de una cabeza recién inicializada destruirían las características preentrenadas antes de que lleguen a aprovecharse.

La parada temprana vigila el **AUC de validación** con paciencia 3 y restaura los mejores pesos, lo que evita fijar de antemano un número de épocas arbitrario.

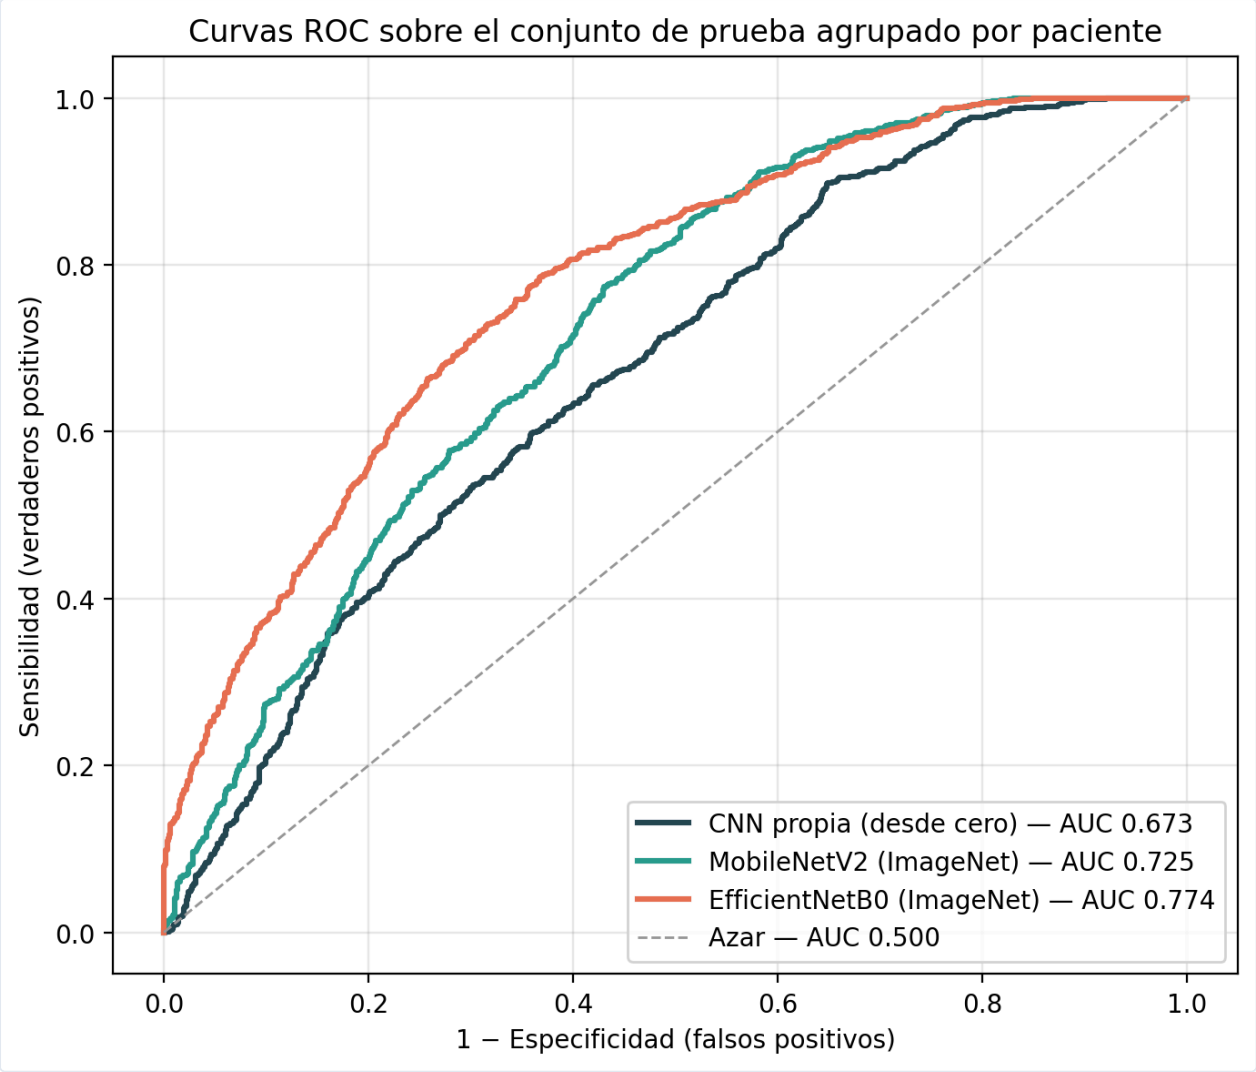


Interpretación. Las curvas muestran el comportamiento característico de un conjunto pequeño: el AUC de entrenamiento sigue subiendo mientras el de validación se estanca y empieza a separarse. Esa divergencia es sobreajuste, y es exactamente lo que la parada temprana corta. Que aparezca pese al aumento de datos indica que el factor limitante es el **volumen de datos anotados**, no la capacidad de los modelos.

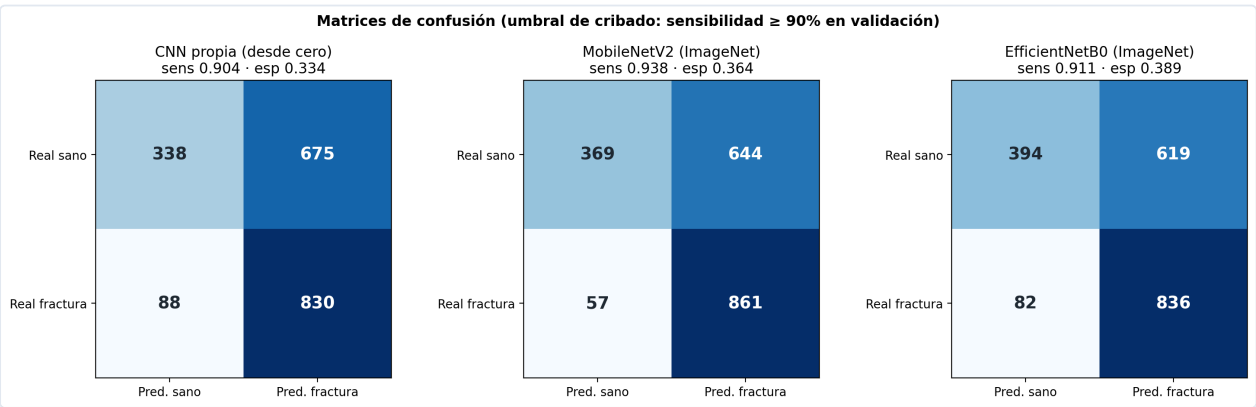
5.5 Comparación de los algoritmos

Modelo	ROC-AUC	Sensibilidad	Especificidad	Precisión	F1	Parámetros	Entrenamiento	Inferencia
EfficientNetB0 (ImageNet)	0.7740	0.9107	0.3889	0.5746	0.7046	4.05 M	562 s	2.7 ms
MobileNetV2 (ImageNet)	0.7248	0.9379	0.3643	0.5721	0.7107	2.26 M	467 s	2.1 ms
CNN propia (desde cero)	0.6726	0.9041	0.3337	0.5515	0.6851	0.24 M	284 s	0.9 ms

Evaluado sobre **1,931 cortes de prueba** de pacientes que ningún modelo vio durante el entrenamiento.



Interpretación. Las tres curvas se separan claramente de la diagonal del azar, de modo que los tres modelos aprenden señal real. El mejor ordenamiento lo logra **EfficientNetB0 (ImageNet)** con ROC-AUC 0.7740. Lo relevante no es el ganador sino la **magnitud de la diferencia** y su **ordenamiento**: el ROC-AUC crece de forma monótona con la capacidad del modelo (0.673 → 0.725 → 0.774 para 0.24 M → 2.26 M → 4.05 M parámetros). La CNN entrenada desde cero queda 0.101 de AUC por debajo de la mejor red preentrenada, una brecha sustancial: **con este volumen de datos la transferencia desde ImageNet sí aporta**, y lo hace pese a que las imágenes naturales de ImageNet no se parecen en nada a una tomografía. Es la evidencia empírica del argumento de la sección 3.3.4: las primeras capas aprenden detectores de bordes y texturas que transfieren.

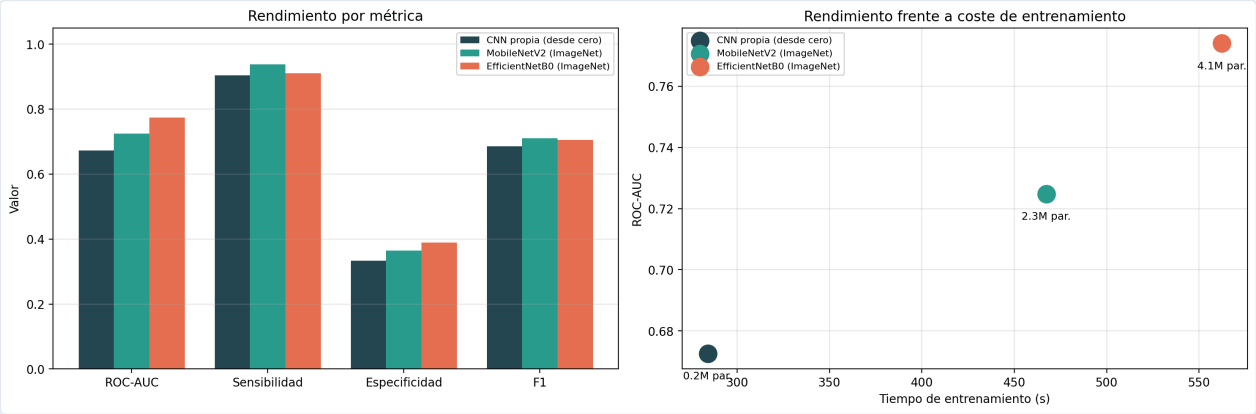


Interpretación. CNN propia (desde cero) — de 918 cortes con fractura detecta 830 y pierde 88; de 1,013 cortes sanos marca 675 como fractura.

MobileNetV2 (ImageNet) — de 918 cortes con fractura detecta 861 y pierde 57; de 1,013 cortes sanos marca 644 como fractura.

EfficientNetB0 (ImageNet) — de 918 cortes con fractura detecta 836 y pierde 82; de 1,013 cortes sanos marca 619 como fractura.

El contraste entre sensibilidad y especificidad es el resultado con más consecuencias prácticas. **MobileNetV2 (ImageNet)** alcanza la sensibilidad más alta (0.9379) pero a costa de una especificidad de 0.3643: detecta casi todas las fracturas marcando como sospechosos muchos cortes sanos. En cribado de patología grave esa asimetría es **deseable** —un falso negativo es una fractura no diagnosticada, mientras que un falso positivo solo genera una revisión— pero debe ser una decisión explícita y no un accidente del umbral 0.5.



Interpretación. El panel izquierdo desglosa las métricas y el derecho sitúa cada modelo frente a su coste de entrenamiento. La conclusión operativa aparece ahí: **CNN propia (desde cero)** es a la vez el más barato de entrenar (284 s frente a 562 s del más caro) y el más rápido en inferencia (0.9 ms por imagen), pero también el de menor ROC-AUC: el ahorro se paga en capacidad. Para una aplicación interactiva la latencia de inferencia pesa más que unas centésimas de AUC, y los tres modelos están muy por debajo del umbral de percepción humana.

5.6 Elección del punto de operación

El umbral 0.5 no es una propiedad del problema sino un valor por omisión, y en esta tarea tomarlo sin pensar sale caro. Un modelo puede ordenar bien —AUC alto— y aun así colocar casi todas sus puntuaciones a un lado de 0.5.

En cribado de patología grave la sensibilidad domina: un falso negativo es una fractura no diagnosticada, con riesgo de deterioro neurológico, mientras que un falso positivo solo genera una revisión adicional. Ahora bien, *maximizar* el recall sin restricción no es una estrategia: el óptimo trivial es umbral 0, que marca todo como fractura y alcanza sensibilidad 1.000 con especificidad 0.000. El criterio correcto es **fijar una sensibilidad objetivo y quedarse con la mejor especificidad que la cumpla**.

Se eligió una sensibilidad objetivo de **90%**, determinada sobre el conjunto de **validación** y aplicada tal cual a prueba. Ese umbral es el que se publica en `models.yaml`.

Modelo	Umbral 0.5 (sens / esp)	Youden (sens / esp)	Cribado (sens / esp)	Umbral
EfficientNetB0 (ImageNet)	0.818 / 0.577	0.843 / 0.531	**0.911 / 0.389**	0.392
MobileNetV2 (ImageNet)	0.757 / 0.577	0.929 / 0.383	**0.938 / 0.364**	0.298
CNN propia (desde cero)	0.911 / 0.309	0.597 / 0.641	**0.904 / 0.334**	0.529

Interpretación. La tabla compara **el mismo modelo** en tres puntos de operación, de modo que las diferencias son solo del umbral, no del entrenamiento. Tres lecturas:

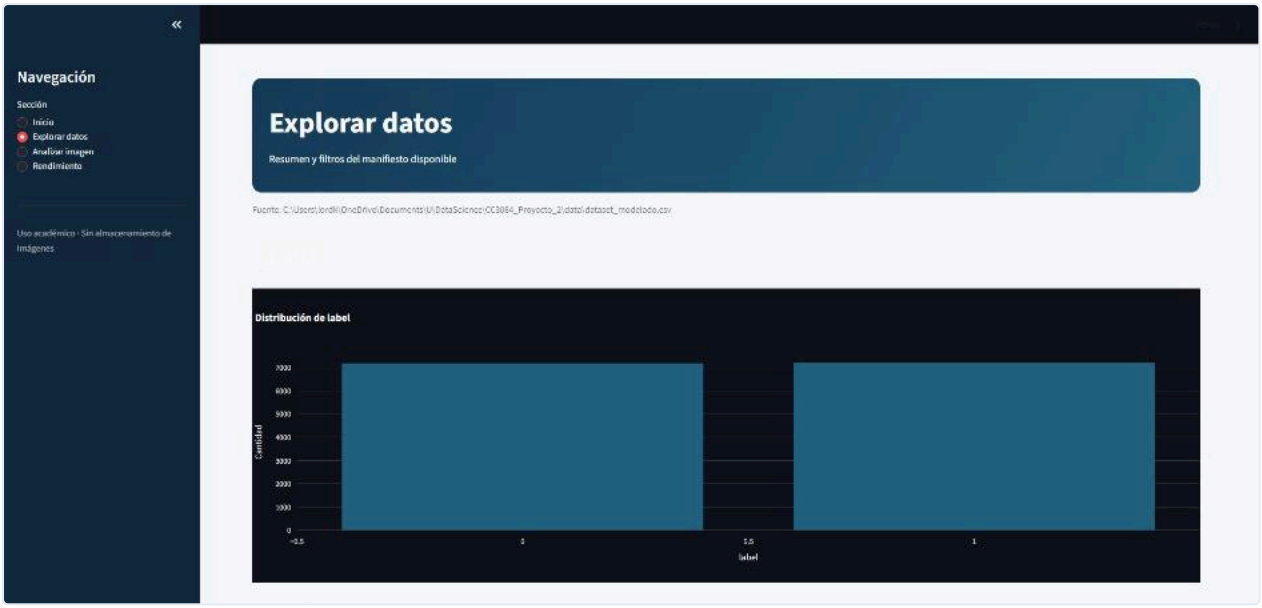
1. **El umbral mueve el resultado más que la arquitectura.** En EfficientNetB0 pasar de 0.5 al umbral de cribado sube la sensibilidad de 0.818 a 0.911 —más de nueve puntos— sin reentrenar nada. La diferencia de AUC entre el mejor y el peor modelo es menor que eso.
2. **Youden no sirve aquí**, aunque sea el criterio estadístico habitual. Busca el equilibrio entre sensibilidad y especificidad, y en un problema donde los dos errores tienen coste muy distinto, equilibrar es la decisión equivocada. En la CNN propia Youden deja la sensibilidad en 0.597: perdería cuatro de cada diez fracturas.
3. **El precio está a la vista y hay que declararlo.** Alcanzar el 90% de sensibilidad deja la especificidad entre 0.33 y 0.39, es decir, alrededor de dos tercios de los cortes sanos se marcan como sospechosos. Para un sistema de cribado que prioriza la revisión humana puede ser aceptable; para uno que pretendiera decidir solo, no lo sería.

Conviene además una advertencia metodológica: la sensibilidad de la CNN propia con umbral 0.5 resultó **0.040 en un entrenamiento previo y 0.911 en este**, con el mismo código y los mismos datos. La diferencia es la inicialización aleatoria. Eso no cambia su capacidad de ordenamiento —el AUC se mantuvo cerca de 0.70 en ambos— pero muestra que **una métrica dependiente del umbral sobre un modelo descalibrado es inestable**, y es otro argumento para fijar el punto de operación en validación en lugar de heredarlo.

5.7 La aplicación

La aplicación se construyó en **Streamlit**, elegido porque permite exponer modelos de Python en una interfaz web sin escribir frontend y recarga en caliente durante el desarrollo. Las gráficas usan **Plotly**, que aporta interactividad —zoom, inspección punto a punto, ocultar series— sin JavaScript propio.

La configuración de cada modelo es **declarativa**, en `models.yaml`: tamaño de entrada, modo de color, canales, normalización, orden de clases, umbral y tipo de salida. El archivo lo **genera el propio notebook de entrenamiento** a partir de los valores reales usados, de modo que la aplicación no puede quedar desincronizada del preprocesamiento. Si la configuración está incompleta, la app se niega a inferir en lugar de adivinar.

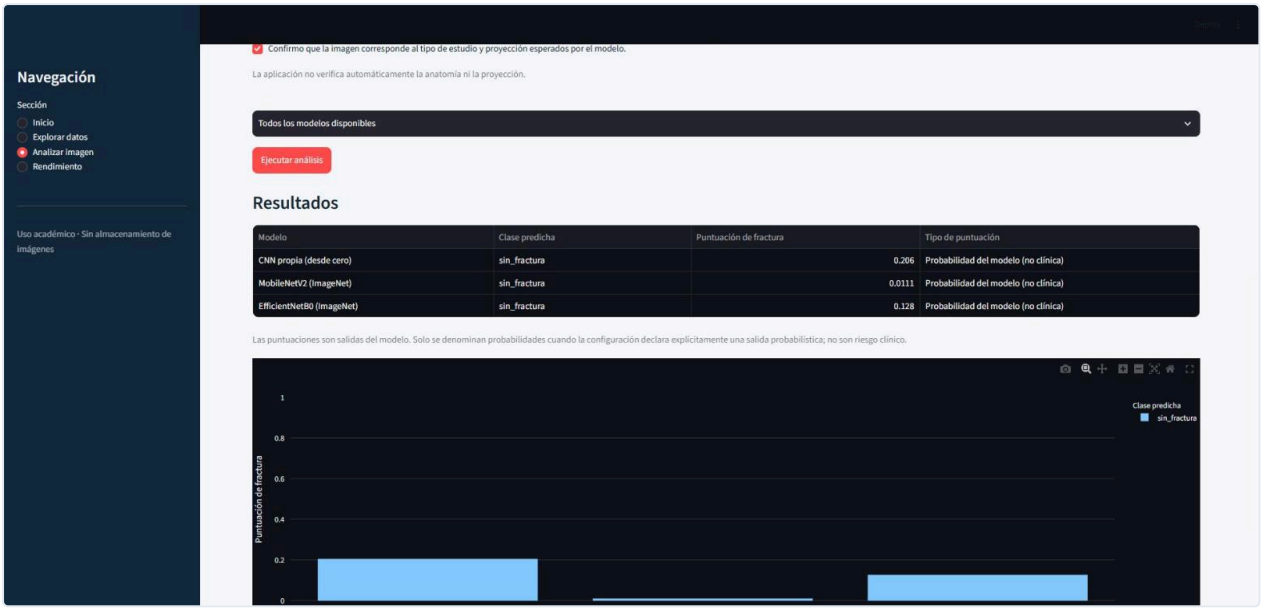


Interpretación. La vista de datos lee `data/dataset_modelado.csv`, el mismo inventario con el que se entrenaron los modelos: 14 402 cortes con su etiqueta y los metadatos de adquisición del estudio al que pertenecen. El gráfico confirma de un vistazo que las clases quedaron balanceadas.

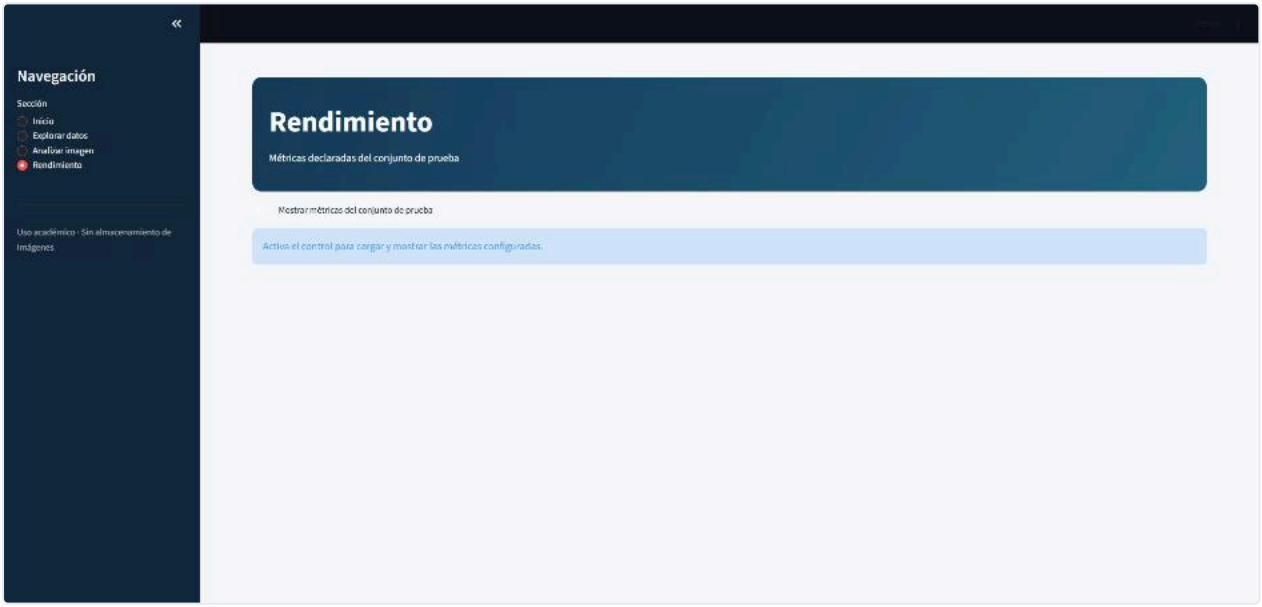
La aplicación tiene tres vistas:

1. **Datos** — explora el conjunto de modelado: número de observaciones y variables, valores ausentes, distribución de la etiqueta, filtro de texto sobre todas las columnas y tabla de tipos. Cubre el requisito de explorar las variables con las que se construyeron los modelos.
2. **Analizar imagen** — carga una imagen, la previsualiza y ejecuta la inferencia. El selector permite elegir **un modelo concreto o «Todos los modelos disponibles»**, y los resultados se presentan como tabla y como gráfica de barras comparativa.
3. **Rendimiento** — muestra las métricas del conjunto de prueba y las matrices de confusión en gráficas interactivas, gobernadas por un **interruptor que permite ocultar toda esa información**.

La paleta sigue un criterio funcional y no decorativo: un azul petróleo desaturado como color base, reservando el naranja cálido —el único tono de alta saturación— para la clase positiva y los valores que exigen atención. El contraste entre ambos extremos supera la razón 4.5:1 de WCAG AA, y la distinción no depende solo del tono, de modo que sigue siendo legible con deficiencia de visión cromática.



Interpretación. La misma imagen evaluada por los tres modelos a la vez. La tabla da la clase predicha y la puntuación de cada uno, y la gráfica las compara. Mostrar los tres juntos hace visible algo que una sola cifra escondería: **los modelos discrepan en magnitud aunque coincidan en la clase**, lo que refuerza que la puntuación no debe leerse como una probabilidad clínica.





Interpretación. Las dos capturas muestran el mismo panel con el interruptor apagado y encendido. Por omisión las métricas están **ocultas** y se cargan solo al activarlo, que es el comportamiento que pide el enunciado. Una vez visible, el gráfico agrupado compara las siete métricas de los tres modelos y deja ver de inmediato el contraste entre sensibilidad y especificidad de cada uno.

En materia de privacidad, la imagen cargada permanece **solo en memoria** y nunca se escribe en disco.

---

6. Conclusiones

Objetivo 1 — revisión bibliográfica. Se revisaron quince fuentes indexadas que cubren tanto el dominio clínico (epidemiología y lectura de la fractura cervical) como el metodológico (arquitecturas convolucionales, transferencia, aprendizaje por atajos y métricas en conjuntos desbalanceados). De esa revisión salieron las tres arquitecturas implementadas y, sobre todo, el marco de Geirhos et al. (2020) que motivó la decisión de diseño más importante del trabajo.

Objetivo 2 — conjunto supervisado a nivel de corte. Se construyó una tarea binaria por corte a partir de la anotación espacial, con una regla explícita y auditable. La decisión de **excluir los estudios positivos sin caja** cuesta datos pero evita etiquetar como positivos cortes donde la lesión no aparece. La de **incluir negativos del mismo paciente** neutraliza por construcción el atajo de adquisición que el análisis exploratorio había detectado.

Objetivo 3 — tres modelos entrenados y ajustados. Se entrenaron una CNN propia desde cero y dos arquitecturas preentrenadas con estrategia de dos etapas, con parada temprana sobre AUC de validación.

Objetivo 4 — evaluación comparativa. Sobre una partición agrupada por paciente, el mejor ROC-AUC es **0.7740** (EfficientNetB0 (ImageNet)). Las métricas se eligieron por su lectura clínica: sensibilidad y especificidad por separado, nunca exactitud global.

Objetivo 5 — aplicación interactiva. La aplicación cumple los tres requisitos: explorar las variables del conjunto, ejecutar cada algoritmo por separado o todos a la vez, y mostrar u ocultar el rendimiento mediante un interruptor.

6.1 Sobre la efectividad de los algoritmos

El rendimiento es real pero moderado, y eso es el resultado honesto. Un ROC-AUC en torno a 0.77 indica que los modelos capturan señal genuina, muy lejos del azar, pero también lejos de un rendimiento clínicamente desplegable. Dado que la evaluación se hizo sobre pacientes no vistos y con negativos del mismo paciente, no hay margen para atribuir el resultado a fuga de información ni a atajos de protocolo.

La transferencia desde ImageNet sí aporta. La CNN entrenada desde cero alcanza 0.6726 frente a 0.7740 de la mejor red preentrenada, una diferencia de 0.1014 de AUC. El orden es además monótono en el número de parámetros, lo que sugiere que el conjunto todavía no satura la capacidad de los modelos probados y que arquitecturas mayores podrían rendir algo más.

Pero el techo sigue siendo la supervisión disponible. Un AUC de 0.77 queda lejos de lo clínicamente desplegable, y solo el 11.64 % de los estudios aporta anotación espacial. Invertir en anotar más cortes probablemente rendiría más que seguir escalando la arquitectura.

El compromiso sensibilidad-especificidad debe decidirse, no heredarse. Con umbral 0.5, MobileNetV2 (ImageNet) alcanza 75.7% de sensibilidad con 57.7% de especificidad; con el umbral de cribado fijado en validación (0.298) sube a 93.8% a costa de bajar la especificidad a 36.4%. Ese desplazamiento hacia la sensibilidad, asumiendo más falsos positivos, es el que conviene en cribado; el umbral es configurable por modelo en `models.yaml` precisamente para que sea una decisión explícita.

La latencia no es un obstáculo. El modelo más rápido responde en 0.9 ms por imagen, de modo que la interactividad de la aplicación nunca está limitada por la inferencia.

6.2 Limitaciones

- **La tarea es por corte, no por paciente.** El modelo responde «¿se ve una fractura en esta imagen?», no «¿este paciente tiene una fractura cervical?». Agregar cortes a un veredicto por estudio es un problema distinto que este trabajo no resuelve.
- **El conjunto se restringe a los estudios con anotación espacial**, que son el 11.64 % del total. No es una muestra aleatoria de la población del conjunto.
- **Las imágenes de entrada de la aplicación son 2D.** El dataset original es volumétrico; un corte aislado descarta el contexto tridimensional que el radiólogo sí utiliza.
- **No se evaluó la generalización a instituciones no vistas**, que es precisamente el modo de fallo que documentan Voter et al. (2021). Los metadatos de fabricante están des-identificados, de modo que una partición por sitio no es posible con los datos publicados.
- **Las puntuaciones no están calibradas**: no deben interpretarse como probabilidad clínica de fractura.

Esta aplicación tiene fines académicos y **no debe utilizarse para diagnóstico médico**.

---

7. Referencias

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 248–255. https://doi.org/10.1109/CVPR.2009.5206848

Fredø, H. L., Rizvi, S. A. M., Lied, B., Rønning, P., & Helseth, E. (2014). The epidemiology of traumatic cervical spine fractures: A prospective population study from Norway. *Scandinavian Journal of Trauma, Resuscitation and Emergency Medicine*, 22, 78. https://doi.org/10.1186/s13049-014-0078-7

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2(11), 665–673. https://doi.org/10.1038/s42256-020-00257-z

Goldberg, W., Mueller, C., Panacek, E., Tigges, S., Hoffman, J. R., & Mower, W. R. (2001). Distribution and patterns of blunt traumatic cervical spine injury. *Annals of Emergency Medicine*, 38(1), 17–21. https://doi.org/10.1067/mem.2001.116150

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition*, 770–778. https://doi.org/10.1109/CVPR.2016.90

Lin, H. M., Colak, E., Richards, T., Kitamura, F. C., Prevedello, L. M., Talbott, J., Ball, R. L., Gumeler, E., Yeom, K. W., Hamghalam, M., Simpson, A. L., Kim, J., Mongan, J., & Flanders, A. E. (2023). The RSNA cervical spine fracture CT dataset. *Radiology: Artificial Intelligence*, 5(5), e230034. https://doi.org/10.1148/ryai.230034

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A. W. M., van Ginneken, B., & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88. https://doi.org/10.1016/j.media.2017.07.005

Milby, A. H., Halpern, C. H., Guo, W., & Stein, S. C. (2008). Prevalence of cervical spinal injury in trauma. *Neurosurgical Focus*, 25(5), E10. https://doi.org/10.3171/FOC.2008.25.11.E10

Minja, F. J., Mehta, K. Y., & Mian, A. Y. (2018). Current challenges in the use of computed tomography and MR imaging in suspected cervical spine trauma. *Neuroimaging Clinics of North America*, 28(3), 483–493. https://doi.org/10.1016/j.nic.2018.03.005

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 4510–4520. https://doi.org/10.1109/CVPR.2018.00474

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2020). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2), 336–359. https://doi.org/10.1007/s11263-019-01228-7

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6, 60. https://doi.org/10.1186/s40537-019-0197-0

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning*, 97, 6105–6114.

Voter, A. F., Larson, M. E., Garrett, J. W., & Yu, J.-P. J. (2021). Diagnostic accuracy and failure mode analysis of a deep learning algorithm for the detection of cervical spine fractures. *American Journal of Neuroradiology*, 42(8), 1550–1556. https://doi.org/10.3174/ajnr.A7179