

Análisis exploratorio del conjunto RSNA 2022 Cervical Spine Fracture Detection

Proyecto 2 — Reto 20 CC3084 · Data Science · Universidad del Valle de Guatemala · Semestre II 2026

Conjunto de datos	RSNA 2022 Cervical Spine Fracture Detection
Alcance	Análisis exploratorio. No se entrena ningún modelo.
Repositorio	(enlace al repositorio GitHub)

Nota de coordinación. Las secciones 1 a 3 corresponden al miembro A (marco conceptual). Las secciones 4 a 6 corresponden al miembro D y se apoyan en los resultados producidos por B (notebooks 01 y 02) y C (notebooks 03 y 04).

1. Situación problemática

(Sección a cargo del miembro A. Debe desarrollar, con la bibliografía semilla ya verificada: qué es una fractura cervical, su incidencia y mecanismos de lesión; las consecuencias del diagnóstico tardío; por qué la TC desplazó a la radiografía simple en adultos; por qué la interpretación es difícil en población mayor con enfermedad degenerativa y osteoporosis; y el argumento de generalización —los modelos previos se entrenaron con representación geográfica limitada y fallaron en datos externos—, que es el vacío que este conjunto multinacional busca llenar.)

2. Problema científico

(Sección a cargo del miembro A. Enunciado preciso, en forma de pregunta.)

3. Objetivos

(Sección a cargo del miembro A. Un objetivo general y al menos tres específicos, medibles y alcanzables dentro de un análisis exploratorio: sin objetivos de modelado, porque este proyecto no entrena modelos.)

4. Descripción de los datos

4.1 Naturaleza del conjunto: son tomografías, no radiografías

La guía del curso describe el reto como un conjunto de "radiografías". **La descripción es incorrecta y la corrección no es un detalle terminológico**, porque cambia la unidad de análisis del proyecto.

El conjunto está formado por **tomografías computarizadas (TC) axiales** almacenadas en formato DICOM. Una radiografía es una proyección bidimensional única. Aquí, en cambio, cada paciente es un **volumen tridimensional** reconstruido a partir de cientos de cortes axiales: la mediana observada es de **314 cortes por estudio**, con un rango de **69 a 1 082**. El conjunto de entrenamiento completo suma aproximadamente 700 000 archivos DICOM y unos 350 GB.

Las consecuencias metodológicas son tres:

1. **La observación es el estudio, no la imagen.** Las 2 019 filas de `train.csv` son volúmenes; los 700 000 archivos `.dcm` son cortes dentro de esos volúmenes. Confundir ambos niveles inflaría artificialmente el tamaño muestral y filtraría información entre particiones (cortes del mismo paciente en *train* y en *test*).
2. **El análisis no puede hacerse en memoria local.** Todo el trabajo se ejecutó en Kaggle Notebooks, donde el conjunto se monta como sistema de archivos de solo lectura, y la lectura de metadatos se limitó a cabeceras (`stop_before_pixels=True`).
3. **La evidencia diagnóstica es tridimensional.** Como muestra la sección 5.4, una fractura suele ser invisible en un corte aislado y solo se aprecia al recorrer el eje craneocaudal o al reconstruir el plano sagital.

El criterio de inclusión oficial del conjunto fue TC axial **sin contraste con cortes finos**, excluyendo a pacientes con cirugía previa por los artefactos metálicos y la anatomía alterada. Los estudios provienen de **12 instituciones en 9 países de 6 continentes**, lo que explica buena parte de la heterogeneidad descrita en la sección 5.2.

4.2 Estructura de los archivos

```
rsna-2022-cervical-spine-fracture-detection/
├─ train.csv                # 2 019 filas × 9 columnas - etiquetas por estudio
├─ test.csv                 # conjunto de prueba público (mínimo)
├─ train_bounding_boxes.csv # 7 217 filas - localización 2D de la lesión
├─ sample_submission.csv
├─ segmentations/          # 87 archivos .nii - máscara vertebral C1-C7 y T1-T12
└─ train_images/<UID>/N.dcm # ≈700 000 cortes DICOM (≈350 GB)
```

El nombre del archivo DICOM corresponde al atributo `InstanceNumber`, es decir, a su posición dentro de la pila. En `train_bounding_boxes.csv`, la columna `slice_number` concatenada con `.dcm` identifica el archivo anotado.

4.3 Número de observaciones y variables

Fuente	Observaciones	Variables	Unidad de observación
<code>train.csv</code>	2 019	9	Estudio de TC (paciente)
<code>train_bounding_boxes.csv</code>	7 217	6	Caja en un corte
<code>segmentations/</code>	87	20 etiquetas de voxel	Volumen segmentado
Metadatos DICOM derivados	2 019	19	Estudio de TC

El conjunto de entrenamiento de Kaggle (2 019 estudios) es un subconjunto del conjunto publicado por la RSNA, que documenta 3 112 estudios en total (1 445 positivos y 1 667 negativos); los restantes se reservan como prueba pública (304) y privada (789). Todas las cifras de este informe corresponden a los **2 019 estudios de entrenamiento**, que son los únicos con etiqueta visible.

4.4 Tabla de variables

Etiquetas (`train.csv`) — 9 variables

Variable	Tipo	Descripción
<code>StudyInstanceUID</code>	<code>object</code>	Identificador único del estudio. Es también el nombre de la carpeta en <code>train_images/</code> .
<code>patient_overall</code>	<code>int64</code> (binaria)	1 si el estudio presenta fractura cervical de cualquier nivel.
<code>C1</code>	<code>int64</code> (binaria)	1 si la vértebra C1 (atlas) presenta fractura.
<code>C2</code>	<code>int64</code> (binaria)	1 si la vértebra C2 (axis) presenta fractura.
<code>C3</code>	<code>int64</code> (binaria)	1 si la vértebra C3 presenta fractura.
<code>C4</code>	<code>int64</code> (binaria)	1 si la vértebra C4 presenta fractura.
<code>C5</code>	<code>int64</code> (binaria)	1 si la vértebra C5 presenta fractura.
<code>C6</code>	<code>int64</code> (binaria)	1 si la vértebra C6 presenta fractura.
<code>C7</code>	<code>int64</code> (binaria)	1 si la vértebra C7 presenta fractura.

La verdad de referencia proviene del **informe original del radiólogo**, no de una relectura hecha para la competencia. Los anotadores podían disputarla y un comité adjudicaba las discrepancias. Esto importa para interpretar la sección 5.1: la etiqueta refleja la práctica clínica real, con su incertidumbre incluida.

Metadatos DICOM derivados (`data/meta_train.csv`) — 19 variables

Extraídas por `src/metadata.py` leyendo tres cabeceras por estudio (primera, media y última) con `stop_before_pixels=True`.

Variable	Tipo	Descripción
<code>StudyInstanceUID</code>	<code>object</code>	Clave de cruce con <code>train.csv</code> .
<code>n_slices</code>	<code>int64</code>	Número de cortes axiales del estudio.
<code>slice_gap</code>	<code>int64</code> (binaria)	1 si la numeración de cortes no es contigua.
<code>slice_thickness</code>	<code>float64</code>	Grosor físico del corte, en mm (<code>SliceThickness</code>).
<code>pixel_spacing_x</code>	<code>float64</code>	Distancia física entre píxeles en el eje x, en mm.
<code>pixel_spacing_y</code>	<code>float64</code>	Distancia física entre píxeles en el eje y, en mm.
<code>rows</code>	<code>float64</code>	Alto del corte en píxeles (<code>Rows</code>).
<code>cols</code>	<code>float64</code>	Ancho del corte en píxeles (<code>Columns</code>).
<code>z_first</code>	<code>float64</code>	Coordenada z del primer corte, en mm (<code>ImagePositionPatient[2]</code>).
<code>z_last</code>	<code>float64</code>	Coordenada z del último corte, en mm.
<code>z_extent</code>	<code>float64</code>	Longitud anatómica cubierta en el eje craneocaudal, en mm.
<code>z_dir</code>	<code>object</code> (categórica)	Sentido de apilamiento: <code>ascendente</code> , <code>descendente</code> o <code>desconocido</code> .
<code>kvp</code>	<code>float64</code>	Voltaje del tubo de rayos X, en kilovoltios pico.
<code>manufacturer</code>	<code>object</code> (categórica)	Fabricante del tomógrafo.
<code>model</code>	<code>object</code> (categórica)	Modelo del tomógrafo.
<code>kernel</code>	<code>object</code> (categórica)	Kernel de reconstrucción.
<code>patient_sex</code>	<code>object</code> (categórica)	Sexo del paciente.
<code>patient_age</code>	<code>object</code>	Edad del paciente.
<code>study_desc</code>	<code>object</code>	Descripción textual del estudio.

Anotación espacial (`train_bounding_boxes.csv`) — 6 variables

Variable	Tipo	Descripción
<code>StudyInstanceUID</code>	<code>object</code>	Estudio al que pertenece la caja.
<code>x</code> , <code>y</code>	<code>float64</code>	Esquina superior izquierda de la caja, en píxeles.
<code>width</code> , <code>height</code>	<code>float64</code>	Ancho y alto de la caja, en píxeles.
<code>slice_number</code>	<code>int64</code>	<code>InstanceNumber</code> del corte anotado.

Segmentaciones (`segmentations/*.nii`)

Volúmenes de etiquetas enteras: `1-7` corresponden a C1–C7, `8-19` a las vértebras torácicas T1–T12, y `0` es fondo. No todos los estudios segmentados incluyen los niveles torácicos completos.


4.5 Calidad de los datos

`src/quality.py` implementa el conjunto de chequeos y `notebooks/05-calidad.ipynb` los ejecuta, exportando `data/reporte_calidad.csv`. El reporte distingue tres estados: `detectado` (hay un problema real), `sin_hallazgos` (se verificó y está limpio) y `no_evaluable` (faltaba la columna necesaria).

El resultado más importante es negativo, y conviene enunciarlo con claridad:

Este conjunto no tiene un problema de suciedad de datos. No hay valores nulos, no hay estudios duplicados, cada uno de los 2 019 UID de `train.csv` tiene su carpeta de imágenes, y la etiqueta agregada es internamente consistente con las etiquetas por nivel. Los problemas reales son de otra naturaleza: **heterogeneidad de adquisición** y **supervisión parcial**.

El reporte ejecutado sobre los 2 019 estudios corre **32 chequeos**: 15 detectan un problema real, 12 verifican y salen limpios, y 5 son informativos. **Ninguno queda sin evaluar.**



#	Hallazgo	Magnitud	Severidad
1	Estudios sin segmentación vertebral	1 932 / 2 019 (95.69 %)	Alta
2	Estudios con eje z descendente	1 822 / 2 019 (90.24 %)	Alta
3	Estudios sin bounding box	1 784 / 2 019 (88.36 %)	Alta
4	Metadatos des-identificados: <code>manufacturer</code> , <code>model</code> , <code>kernel</code> , <code>kvp</code> , <code>patient_sex</code> , <code>patient_age</code> , <code>study_desc</code>	7 columnas, 2 019 / 2 019 (100 %)	Alta
5	Valores distintos de <code>pixel_spacing_x</code>	324 valores (0.190 – 0.713 mm)	Media
6	Valores distintos de <code>slice_thickness</code>	10 valores (0.488 – 1.000 mm)	Media
7	Estudios con caja <code>y</code> segmentación (única vía de validación cruzada)	40 / 2 019 (1.98 %)	Media
8	Combinaciones distintas de <code>rows × cols</code>	3 combinaciones; 3 estudios (0.15 %) no son 512×512	Media
9	Cobertura <code>z_extent</code> atípica por IQR	29 / 2 019 (1.44 %), rango 48.5 – 334.4 mm	Media
10	<code>n_slices</code> atípico por IQR	27 / 2 019 (1.34 %), rango 69 – 1 082	Baja
11	Inconsistencia <code>patient_overall</code> vs <code>OR(C1-C7)</code>	0 / 2 019 (0 %)	Verificado, limpio
12	Valores nulos en las 8 etiquetas	0	Verificado, limpio
13	Estudios duplicados	0	Verificado, limpio
14	UID de <code>train.csv</code> sin carpeta de imágenes	0	Verificado, limpio
15	Huecos en la numeración de cortes (<code>slice_gap</code>)	0	Verificado, limpio
16	Estudios sin <code>ImagePositionPatient</code> legible	0	Verificado, limpio
17	Cajas que exceden el marco del corte	0	Verificado, limpio
18	Estudios con caja pero <code>patient_overall = 0</code>	0	Verificado, limpio

El hallazgo nuevo y más importante de esta tabla es el número 2. El eje z descendente no es una excepción que afecte a unos pocos estudios: es **la norma, con el 90.24 % de los casos**. Solo 197 estudios apilan en sentido ascendente. Cualquier pipeline que asuma un sentido craneocaudal fijo —o que ordene los cortes por el nombre del archivo— procesará nueve de cada diez volúmenes al revés. Y lo hará en silencio, sin lanzar ningún error.

Conviene leerlo junto al hallazgo 15: **no hay un solo estudio con huecos en la numeración**, y los 2 019 tienen `ImagePositionPatient` legible (hallazgo 16). Es decir, el orden de los archivos es perfectamente contiguo y aun así mayoritariamente inverso al anatómico. La contigüidad invita precisamente al error:

como la numeración no tiene saltos, ordenar por nombre *parece* correcto.

Sobre la des-identificación (hallazgo 4). Son **siete** columnas constantes en "Desconocido", no tres: además de `manufacturer`, `kernel` y `patient_sex`, también `model`, `kvp`, `patient_age` y `study_desc`. El conjunto fue des-identificado antes de publicarse y esos tags se eliminaron de las cabeceras. Dos consecuencias: la prueba de asociación entre fabricante y etiqueta es vacía ($\chi^2 = 0.00$, $p = 1.0000$, que no significa ausencia de asociación sino ausencia de datos), y **no es posible analizar sesgo demográfico ni por sitio de origen** con los datos publicados.

Sobre `rows × cols` (hallazgo 8). 2 016 estudios son 512×512, dos son 768×768 y uno es 512×519. Como el 99.85 % es 512×512, expresar el área de la lesión como porcentaje de 512×512 (sección 5.3) es válido, pero esos tres estudios deben recalcularse con sus dimensiones propias si se usan para medir tamaños.

4.6 Operaciones de limpieza y preprocesamiento

Cada operación se deriva de un hallazgo concreto del análisis, no de una lista genérica. Ninguna de ellas elimina observaciones: la dispersión observada es variabilidad legítima de protocolo entre 12 instituciones, y descartarla sesgaría el conjunto justamente en la dirección que el conjunto pretende corregir.

1. Normalizar la orientación antes de cualquier operación volumétrica. *Deriva de:* el hallazgo más contundente del reporte de calidad. **El 90.24 % de los estudios (1 822 de 2 019) apila en sentido descendente**, y solo 197 lo hacen en sentido ascendente. A la vez, la numeración de archivos es contigua en el 100 % de los casos (`slice_gap = 0` en todos) y los 2 019 tienen `ImagePositionPatient` legible. Esa combinación es una trampa: como no hay huecos, ordenar por el nombre del archivo parece correcto y no produce ningún error visible, pero invierte nueve de cada diez volúmenes. *Operación:* ordenar los cortes por `ImagePositionPatient[2]` —nunca por nombre de archivo ni por `InstanceNumber`—, registrar `z_dir` como variable de control y reorientar las máscaras NIfTI, que están almacenadas en plano sagital mientras los DICOM son axiales. Toda superposición de máscara debe validarse **visualmente** antes de darla por buena; la mera coincidencia de dimensiones no demuestra alineación. Dado que el sentido descendente es el mayoritario, conviene además fijar una convención explícita del proyecto (por ejemplo, z creciente = craneal → caudal) y afirmarla con un `assert` en el pipeline, en lugar de confiar en que el orden de lectura sea el correcto.

2. Convertir a unidades Hounsfield y remuestrear a espaciado isotrópico 1×1×1 mm. *Deriva de:* los píxeles crudos no son unidades HU, y el espaciado varía entre estudios (`pixel_spacing` de 0.190 a 0.713 mm; `slice_thickness` de 0.488 a 1.000 mm). *Operación:* aplicar `HU = pixel_array × RescaleSlope + RescaleIntercept` y luego remuestrear. Sin esto, un mismo número de píxeles representa distintos milímetros según el hospital de origen, y cualquier medida de tamaño de lesión es incomparable entre estudios.

3. Aplicar ventana ósea y descartar el rango de aire. *Deriva de:* el rango HU va de −1 000 (aire) a +3 000 (hueso cortical), mientras la pantalla y la mayoría de las arquitecturas trabajan sobre 256 niveles. La figura 5.4.1 muestra que sin ventana la imagen es prácticamente inservible. *Operación:* ventana ósea (centro 400, ancho 1 800) como vista primaria, y ventana de tejido blando (centro 40, ancho 400) como vista complementaria. Recortar el rango de aire elimina voxels que no aportan señal diagnóstica.

4. Recortar a la región C1–C7 usando las segmentaciones. *Deriva de:* el recorrido anatómico real va de 48.5 mm a 334.4 mm. El extremo inferior es un estudio cervical muy focalizado y el superior una cobertura cervicotorácica amplia: en ambos casos la proporción del volumen que ocupa C1–C7 varía bastante.

Operación: usar las 87 segmentaciones disponibles para entrenar o calibrar un localizador vertebral y propagarlo al resto. Esto homogeneiza el campo de visión sin descartar ningún estudio. Debe documentarse que el recorte propagado introduce un error no cuantificado en este EDA.


5. Decidir explícitamente el tratamiento de las etiquetas ambiguas. *Deriva de:* la documentación oficial advierte que puede haber estudios positivos sin nivel asignado. **En este subconjunto de entrenamiento la inconsistencia no se materializa: los 2 019 estudios cumplen `patient_overall == OR(C1..C7)`.**

Operación: mantener el chequeo en el pipeline (`ETI-03` del reporte) porque los conjuntos de prueba pública y privada pueden comportarse distinto, y porque la ausencia de inconsistencias en *train* no garantiza su ausencia en producción. La regla adoptada —si aparece un positivo sin nivel, se conserva para la tarea binaria y se excluye de la tarea por nivel— queda fijada de antemano, no improvisada al encontrarlo.

6. Partición estratificada por `patient_overall` y por nivel. *Deriva de:* dos hechos. El desbalance entre niveles es fuerte (C7 con 393 casos frente a C3 con 73, una razón de 5.4 : 1), y las variables de adquisición difieren significativamente entre clases, siendo `n_slices` la de mayor asociación ($p = 1.8 \times 10^{-8}$) una vez corregido `z_extent` (sección 5.2). *Operación:* estratificar por `patient_overall` y por nivel fracturado, agrupando siempre por `StudyInstanceUID` para que ningún corte del mismo paciente caiga a ambos lados de la partición. La estratificación por fabricante prevista en el diseño original **no es aplicable**, porque la variable está des-identificada —junto con `model`, `kernel`, `kvp`, `patient_sex`, `patient_age` y `study_desc`—; en su lugar debe estratificarse por `n_slices` discretizado, que es el mejor sustituto observable del protocolo de adquisición.

5. Hallazgos


5.1 Etiquetas: qué se está prediciendo



Interpretación. De los 2 019 estudios, **961 (47.60 %) presentan fractura cervical**. La clase binaria está prácticamente balanceada, lo que es inusual en imagen médica y significa que el reto **no** está en el desbalance de la tarea principal: una métrica de exactitud simple no queda inflada por una clase mayoritaria. El desbalance aparece un nivel más abajo, al pasar de "¿hay fractura?" a "¿en qué vértebra?". Ahí las frecuencias se separan con claridad: **C7 con 393 casos (19.47 % del conjunto, 40.89 % de los positivos)**, seguida de **C2 con 285** y **C6 con 277**; en el otro extremo, **C3 con solo 73 casos (3.62 %)**. La razón entre el nivel más frecuente y el más raro es de **5.4 : 1**, suficiente para que un clasificador multietiqueta sin ponderación aprenda a ignorar C3 y C4.

Los 961 pacientes positivos acumulan **1 444 niveles fracturados**, es decir **1.50 vértebras fracturadas por paciente positivo**. La tarea es multietiqueta, no multiclase: las etiquetas no son mutuamente excluyentes.


Validación contra la literatura. C2, C6 y C7 concentran **955 de las 1 444 fracturas, el 66.14 %**, y C7 es efectivamente el nivel más frecuente. La cifra es consistente con las dos referencias disponibles: el 62.4 % que reporta la descripción oficial del conjunto completo (Lin et al., 2023) y el 63.3 % que Goldberg et al. (2001) midieron en un estudio multicéntrico de 21 instituciones. La diferencia de unos 3 puntos porcentuales respecto del 62.4 % era esperable, porque aquella cifra se calcula sobre los 3 112 estudios del conjunto publicado y esta sobre los 2 019 de entrenamiento. Que un subconjunto de 2 019 estudios de 12 instituciones reproduzca un patrón epidemiológico descrito hace dos décadas es una **verificación externa de la validez del conjunto**: no es una muestra sesgada hacia un tipo de fractura infrecuente.



Interpretación. Al ser todas las variables binarias, la correlación de Pearson entre ellas equivale al coeficiente phi. No hay ninguna correlación fuerte —ninguna supera 0.85, el umbral que obligaría a eliminar variables redundantes—, pero los coeficientes más altos aparecen sistemáticamente **entre vértebras adyacentes**. Tiene sentido biomecánico: la fractura ocurre porque una fuerza se aplica sobre un segmento, y esa fuerza se disipa hacia las vértebras contiguas. La matriz de co-ocurrencia confirma el mismo patrón en conteos absolutos. La implicación para el modelado es que **tratar C1–C7 como siete problemas binarios independientes desperdicia estructura**: la vecindad anatómica es información aprovechable.

El desglose de combinaciones refuerza la lectura. De las 393 fracturas de C7, **223 son aisladas** y las 170 restantes (43 %) coexisten con otro nivel, muy frecuentemente C6 (**C6 + C7** aparece 77 veces, la cuarta combinación más común). En C2, 180 de 285 son aisladas. La combinación **C1 + C2** aparece 42 veces, coherente con el complejo atlanto-axial como unidad funcional.

5.2 Metadatos de adquisición: heterogeneidad y riesgo de atajo




Interpretación. `slice_thickness` y `pixel_spacing` son notablemente homogéneos —medianas de **0.625 mm** y **0.312 mm**, con desviaciones estándar pequeñas—, lo cual concuerda con el criterio de inclusión oficial de corte fino. `slice_thickness` no produce **ningún** valor atípico por IQR, el único caso así en todo el conjunto; toma apenas **10 valores distintos**, dominados por 0.625 mm (1 041 estudios) y 1.000 mm (618). `pixel_spacing`, en cambio, toma **324 valores distintos** entre 0.190 y 0.713 mm, siempre isotrópico en el plano (`pixel_spacing_x` = `pixel_spacing_y` en los 2 019 estudios). La heterogeneidad de resolución está por tanto en el plano axial, no en el eje z.


Corrección respecto de la figura. La figura anterior y el notebook 02 calculan `z_extent` como `n_slices × slice_thickness`. Al recalcarlo como `|z_last - z_first|` con `ImagePositionPatient[2]` —el recorrido anatómico real— las cifras cambian de forma sustancial, y la lectura correcta es la segunda:

	Aproximación <code>n_slices × grosor</code>	Recorrido físico real
Mediana	220.6 mm	198.0 mm
Media	246.1 mm	197.6 mm
Desviación estándar	81.3 mm	28.9 mm
Rango	33.7 – 642.6 mm	48.5 – 334.4 mm

La aproximación **sobreestima en 2 017 de los 2 019 estudios (99.9 %)**; solo dos la subestiman. La mediana de sobreestimación es de apenas 1.0 mm, pero la media es de 48.5 mm y el máximo de 325 mm. Esa cola pesada es exactamente el solapamiento entre cortes: cuando el incremento de reconstrucción es menor que el grosor nominal, multiplicar cuenta el mismo tejido varias veces.




Interpretación. El panel izquierdo superpone las dos distribuciones: la aproximación (naranja) arrastra una cola larga hasta 642 mm que **no existe** en la medida real (verde), concentrada alrededor de 200 mm. El panel central sitúa cada estudio frente a la diagonal de identidad —donde caería si no hubiera solapamiento— y revela algo que la tabla no muestra: los puntos se agrupan en **bandas diagonales discretas**, una por cada valor de `slice_thickness`. Es la huella de los protocolos de reconstrucción de los distintos sitios. El panel derecho cuantifica el exceso: un pico enorme en ~1 mm (la mayoría de estudios reconstruye con incremento $\approx$ grosor) y grupos secundarios en torno a 50, 100 y 200 mm, que son los estudios con solapamiento de $\frac{1}{2}$, $\frac{1}{3}$ y $\frac{1}{4}$ de corte.



Interpretación. Las cuatro variables de adquisición medidas correctamente. `slice_thickness` es casi bimodal (0.625 y 1.000 mm concentran 1 659 de 2 019 estudios), `pixel_spacing` es unimodal con cola derecha, y `z_extent` real resulta marcadamente más simétrico y compacto que en la figura anterior de la sección. Es esta versión —no la del notebook 02— la que sustenta las cifras del texto.


La corrección cambia la conclusión. Con el recorrido real, **la cobertura anatómica es mucho más homogénea de lo que sugería la aproximación**: la desviación estándar cae de 81.3 mm a 28.9 mm y el máximo de 642.6 mm a 334.4 mm. No hay barridos de politrauma de cuerpo entero disfrazados en el conjunto; 334 mm es una cobertura cervicotorácica amplia, pero plausible. El criterio de inclusión oficial se sostiene mejor de lo que parecía. Lo que sí varía mucho entre sitios es **cuántos cortes se usan para cubrir esa longitud similar** —`n_slices` va de 69 a 1 082 con media 352 frente a mediana 314—, es decir, el grado de solapamiento en la reconstrucción.

El análisis de atípicos por IQR sobre las variables correctas arroja **27 casos en `n_slices` (1.34 %)** y **29 en `z_extent` físico (1.44 %)**, muy por debajo de los 84 (4.16 %) que daba la aproximación. **No se eliminan.** Descartarlos borraría los protocolos menos representados, empeorando el problema de generalización que motiva el conjunto. La normalización correcta es el remuestreo isotrópico y el recorte a C1–C7 (operaciones 2 y 4 de la sección 4.6).




Interpretación. Ninguna correlación entre variables numéricas supera 0.85, así que no hay redundancia que obligue a eliminar variables. Las asociaciones más fuertes son las esperadas por construcción: `n_slices` con `z_extent` —un recorrido más largo requiere más cortes— y `n_slices` con `slice_thickness`, con **signo negativo**, porque para cubrir la misma longitud con cortes más gruesos se

necesitan menos. El diagrama de dispersión muestra que esta última relación **no es lineal sino hiperbólica**, lo cual es aritmética, no un hallazgo empírico: $z_extent \approx n_slices \times slice_thickness$, de modo que a z_extent aproximadamente constante, n_slices varía como el inverso del grosor. La consecuencia práctica es que un coeficiente de Pearson **subestima** esta dependencia; la relación es determinista, no estadística.



Interpretación — riesgo de *shortcut learning*. La prueba prevista para detectar atajos, χ^2 entre fabricante y `patient_overall`, es **inaplicable**: la variable está des-identificada y toma un solo valor, de modo que el resultado ($\chi^2 = 0.00$, $p = 1.0000$) no informa nada. Sin embargo, las pruebas de Mann-Whitney sobre las variables de adquisición **sí detectan diferencias significativas** entre estudios positivos y negativos:




Variable	U	p	P(positivo > negativo)
<code>n_slices</code>	434 736	1.82×10^{-8}	0.428
<code>z_extent</code> (recorrido físico)	469 875	3.26×10^{-3}	0.462
<code>slice_thickness</code>	535 033	2.56×10^{-2}	0.526

Aquí la corrección de `z_extent` vuelve a importar. Calculado con la aproximación $n_slices \times \text{grosor}$, `z_extent` parecía la señal más fuerte del conjunto ($p = 8.47 \times 10^{-10}$, efecto 0.421). Recalculado con el recorrido anatómico real, **el efecto se reduce a menos de la mitad** ($p = 3.26 \times 10^{-3}$, efecto 0.462). La diferencia aparente no estaba en la anatomía del paciente sino en el solapamiento de reconstrucción —es decir, en el protocolo—, y al medir la longitud real casi se disuelve. Con la corrección, `n_slices` **pasa a ser la variable con mayor asociación**, lo que es coherente: es la que más directamente codifica el protocolo del sitio.

La lectura correcta requiere separar significancia de magnitud. Con $n = 2\,019$ la significancia se alcanza con efectos pequeños, y eso es lo que ocurre: el tamaño de efecto de lenguaje común se aleja del valor nulo de 0.50 apenas entre 0.026 y 0.072. En términos prácticos, los estudios positivos tienden a tener **algo menos cortes** que los negativos, pero la superposición entre ambas distribuciones es casi total y ninguna de estas variables permitiría clasificar por sí sola.


Aun así, el hallazgo **no es descartable**, y esa es la conclusión operativa: existe una asociación real, pequeña pero sistemática, entre el protocolo de adquisición y la etiqueta. Una red que reciba el volumen completo puede aprender a leer el muestreo del barrido en lugar de la discontinuidad ósea. Como **manufacturer** no está disponible para controlar el efecto, **n_slices discretizado es el mejor sustituto observable del sitio de origen** y debe usarse para estratificar la partición (operación 6 de la sección 4.6). Recortar a C1–C7 y remuestrear a espaciado isotrópico antes de clasificar elimina buena parte de este atajo por construcción, porque homogeneiza a la vez el campo de visión y la densidad de muestreo.

5.3 Anotación espacial: el hallazgo central del reto




Interpretación — este es el resultado más importante del análisis. La región delimitada por la caja ocupa una **mediana del 2.415 % del corte de 512×512** , con percentil 95 en 11.02 % y percentil 99 en 18.04 %. En píxeles: unos **6 331 de los 262 144** del campo de visión. Dicho de otro modo, **el fondo supera a la región de interés en una proporción cercana a 41 : 1**, y la caja es todavía un **límite superior** del tamaño real de la lesión, porque incluye la vértebra y tejido circundante; la discontinuidad ósea propiamente dicha es menor.



Esto condiciona toda la estrategia de modelado. Una clasificación directa del volumen completo obliga a la red a encontrar una señal que ocupa el 2 % de la imagen, y en posiciones que varían entre pacientes. El diagrama de dispersión ancho-vs-alto muestra además que las cajas son mayoritariamente **más anchas que altas** (razón de aspecto mediana 1.25, media 1.36), consistente con la orientación de los cuerpos vertebrales en el plano axial. Este único número —2.4 %— es el argumento cuantitativo que justifica un **enfoque en dos etapas**: localizar primero, clasificar después sobre el recorte.



Interpretación. Un estudio anotado tiene una **mediana de 24 cajas**, con media 30.7 y un máximo de **167**. La distribución tiene una cola derecha marcada. La lectura que hay que evitar es contar cajas como si fueran fracturas: una sola fractura se anota en todos los cortes consecutivos donde es visible, de modo que **el número de cajas mide la extensión craneocaudal de la lesión, no el número de lesiones independientes**. Las 7 217 cajas del archivo corresponden a un número de fracturas sustancialmente menor.




Interpretación. La posición relativa mediana de las cajas es **0.543**, es decir, cerca del centro de la pila, y la distribución se concentra en la región central. Dos advertencias impiden leer esto como una localización anatómica. Primera, la razón `slice_number / n_slices` describe posición **dentro del archivo**, no coordenada física; como el sentido craneocaudal se invierte entre estudios, una misma vértebra cae en posiciones relativas opuestas según el estudio. Segunda, el denominador varía con el protocolo: en un politrauma de 642 mm, la región cervical ocupa una fracción mucho menor de la pila que en un estudio cervical focalizado. La concentración central es, por tanto, compatible con que el cuello quede centrado en el barrido, pero **no permite recortar por posición relativa fija**: para eso hay que usar las segmentaciones.



Interpretación. La segunda figura resume la estructura piramidal de la supervisión: los 2 019 estudios tienen etiqueta binaria y por nivel al 100 %, pero la localización cae abruptamente. Las cajas cubren **235 estudios, el 11.64 % del conjunto y solo el 24.45 % de los casos positivos**. Las segmentaciones cubren **87 estudios (4.31 %)**. Y la intersección —los estudios con ambos tipos de anotación— es de apenas **40 estudios (1.98 %)**: 195 tienen solo caja y 47 solo segmentación. Tres consecuencias:


1. **La ausencia de caja no significa ausencia de fractura.** Tres de cada cuatro casos positivos no tienen localización. Usar los estudios sin caja como negativos para un detector introduciría ruido de etiqueta masivo.
2. Una etapa de localización supervisada dispone, como techo, de menos de la cuarta parte de los positivos.
3. Esos **40 estudios son el único subconjunto donde puede verificarse que la máscara NIfTI quedó correctamente alineada con el volumen DICOM**, comprobando que la caja cae dentro de la vértebra que la máscara identifica. Es un recurso de validación escaso y conviene no gastarlo como conjunto de prueba.



Interpretación. El volumen segmentado por vértebra dibuja un perfil en U: **C2 y C7 son las más voluminosas** ($\approx 276\,700$ y $\approx 276\,500$ voxeles de media respectivamente), mientras **C3 y C4 son las más pequeñas** ($\approx 185\,300$ y $\approx 187\,200$). El patrón es anatómicamente correcto —el axis y la séptima cervical son las vértebras de mayor tamaño del segmento— y sirve como **verificación de que la carga y orientación de las máscaras es coherente**: una máscara mal orientada no reproduciría el perfil anatómico esperado. La dispersión es alta (desviación estándar del orden del 60 % de la media, máximos que cuadruplican la mediana) porque los conteos están en **voxels, no en mm³**: sin multiplicar por el volumen de voxel de cada cabecera, los estudios de mayor resolución producen conteos mayores para la misma anatomía. Para comparar volúmenes físicos habría que incorporar el espaciado.


Además, el **100 % de las máscaras contiene al menos una etiqueta torácica**, pero la cobertura por nivel varía entre 0 % y 100 %: prácticamente todas incluyen T1, casi ninguna llega a T12. Recortar "de C1 a T1" es viable; asumir T1–T12 completos no lo es.

5.4 Evidencia visual: por qué el problema es difícil



Interpretación. Las tres imágenes son **el mismo corte DICOM**. A la izquierda, la autoescala sobre el rango HU completo (−1 000 a +3 000) produce una imagen inservible: el aire y el hueso comprimen todo el tejido intermedio en unos pocos niveles de gris. En el centro, la ventana de tejido blando (C = 40, A = 400) resalta músculo y estructuras vecinas pero satura el hueso. A la derecha, la ventana ósea (C = 400, A = 1 800) conserva el contraste entre cortical y trabécula, que es donde se manifiesta una fractura. La conclusión operativa es que **la elección de ventana no es un ajuste estético sino una decisión de preprocesamiento que determina si la señal diagnóstica está presente o no** en la entrada del modelo.

Localización anotada — corte 397




Interpretación. La caja del ejemplo ocupa **3.016 % del corte**, muy cerca de la mediana global de 2.415 %. La figura hace tangible la cifra de la sección 5.3: la región anotada es un rectángulo pequeño que, sin la anotación, compite con más de 260 000 píxeles de campo de visión. Es la traducción visual del argumento a favor de localizar antes de clasificar.


Reconstrucción multiplanar — 1.2.826.0.1.3680043.25772



Interpretación. La vista axial es la adquisición original; las vistas sagital y coronal se obtienen reordenando la pila por `ImagePositionPatient[2]` y ajustando las proporciones con `PixelSpacing` y la separación real entre cortes, para que la geometría no quede deformada. **La vista sagital es la que el radiólogo usa para evaluar la alineación cervical** y la continuidad de los muros vertebrales a lo largo del eje craneocaudal: es ahí donde una discontinuidad invisible en un corte axial aislado se vuelve evidente. Que esta reconstrucción dependa por completo del ordenamiento correcto del volumen es la justificación de la operación 1 de la sección 4.6.



Interpretación. La máscara se superpone al corte coloreada por vértebra, tras reorientarla del plano sagital en que se almacena el NIfTI al plano axial del DICOM. Las formas de `(208, 512, 512)` coinciden entre máscara y volumen, pero **la coincidencia de dimensiones no demuestra alineación**: una máscara espejada o invertida en z tiene exactamente la misma forma. La validación es visual y obligatoria —cada color debe permanecer dentro del cuerpo y el arco de su vértebra, sin reflejo izquierda-derecha ni inversión craneocaudal—, y en esta figura se cumple. Es la comprobación que autoriza a usar las segmentaciones para recortar C1–C7 en la operación 4.



Interpretación. La rejilla compara cortes axiales en ventana ósea de tres casos positivos, tomados en los cortes anotados, y tres negativos seleccionados en posiciones relativas comparables de su pila para reducir las diferencias de cobertura anatómica. El punto de la figura es negativo y deliberado: **a simple vista, en un corte aislado, las dos filas no son distinguibles.** La discontinuidad cortical que define la fractura es sutil a esta escala, y la lectura clínica requiere recorrer el volumen y consultar la reconstrucción sagital. La rejilla es ilustrativa y no constituye una evaluación diagnóstica, pero explica con claridad por qué un clasificador que opere corte a corte, sin contexto tridimensional ni localización previa, parte en desventaja.

6. Conclusiones y siguientes pasos

6.1 Síntesis de los hallazgos

El conjunto está limpio; el problema es otro. De 32 chequeos de calidad, 12 verifican y salen limpios: cero nulos, cero duplicados, cero UID sin imágenes, cero huecos en la numeración de cortes, cero cajas fuera de marco y consistencia total entre `patient_overall` y `OR(C1..C7)` en los 2 019 estudios. Las horas que un proyecto típico dedica a imputación y deduplicación aquí no aplican. Los tres obstáculos reales son la **orientación no normalizada**, la **heterogeneidad de adquisición** entre 12 instituciones y la **supervisión parcial** de la anotación espacial.

Nueve de cada diez volúmenes están apilados en sentido descendente. 1 822 de 2 019 estudios (90.24 %) tienen el eje z descendente. Es el hallazgo con mayor potencial de daño silencioso del análisis, y se agrava porque la numeración de archivos es contigua en el 100 % de los casos: ordenar por nombre

parece correcto, no lanza ningún error, y procesa la gran mayoría de los volúmenes invertidos.

La tarea binaria está balanceada; la tarea por nivel no. El 47.60 % de los estudios son positivos, una proporción cómoda. Pero al bajar al nivel vertebral, C7 (393 casos) supera a C3 (73) en razón de 5.4 : 1, y los 961 positivos acumulan 1 444 niveles fracturados: es un problema multietiqueta con estructura de vecindad, donde las correlaciones más altas se dan entre vértebras adyacentes.

La distribución anatómica reproduce la literatura. C2, C6 y C7 concentran el 66.14 % de las fracturas y C7 es el nivel más frecuente, en línea con el 62.4 % del conjunto completo (Lin et al., 2023) y el 63.3 % de Goldberg et al. (2001). El conjunto de entrenamiento no está sesgado hacia un patrón epidemiológico atípico.

La lesión ocupa el 2.4 % del corte. Es el hallazgo que más condiciona el diseño posterior: mediana de 2.415 % del campo de visión de 512×512 , con la caja actuando como límite superior del tamaño real. La relación fondo-a-lesión ronda 41 : 1.

La anotación espacial es escasa y no es exhaustiva. Solo el 11.64 % de los estudios tiene caja, el 4.31 % tiene segmentación y apenas el 1.98 % tiene ambas. Tres de cada cuatro casos positivos carecen de localización, de modo que la ausencia de caja no puede interpretarse como ausencia de fractura.

Existe un riesgo de atajo pequeño pero real. Siete columnas de metadatos están des-identificadas (`manufacturer`, `model`, `kernel`, `kvp`, `patient_sex`, `patient_age`, `study_desc`), de modo que la prueba prevista para detectarlo es vacía. Las variables de adquisición sí difieren de forma significativa entre clases, con `n_slices` como la más asociada ($p = 1.8 \times 10^{-8}$, $P(\text{pos} > \text{neg}) = 0.428$), aunque con tamaños de efecto pequeños. La asociación no basta para clasificar, pero sí para que un modelo la explote como pista espuria si no se controla.

Medir bien cambia la conclusión. Calcular `z_extent` como `n_slices × grosor` sobreestima el recorrido anatómico en el 99.9 % de los estudios y triplica su desviación estándar (81.3 mm frente a 28.9 mm reales). Con la medida correcta, la cobertura del conjunto resulta bastante homogénea (48.5 – 334.4 mm) y el que parecía el atajo más fuerte se reduce a menos de la mitad (de $p = 8.5 \times 10^{-10}$ a $p = 3.3 \times 10^{-3}$). Lo que variaba no era la anatomía sino el solapamiento de reconstrucción.

6.2 Implicaciones para las siguientes etapas

1. Adoptar un enfoque en dos etapas. Es la conclusión que se desprende directamente de los números: si la lesión ocupa el 2.4 % del corte, clasificar el volumen completo obliga al modelo a buscar una señal diminuta en un campo enorme. La alternativa es localizar o segmentar primero las vértebras C1–C7, recortar cada una y clasificar sobre el recorte. El recorte resuelve simultáneamente tres problemas: reduce la relación fondo-a-lesión, homogeneiza el campo de visión entre protocolos —neutralizando el atajo por `z_extent`— y convierte un problema multietiqueta en siete decisiones locales comparables entre sí.

2. Tratar la localización como etiqueta débil, nunca como verdad exhaustiva. Las cajas y las segmentaciones sirven para entrenar la etapa de localización y para validar la orientación, pero los estudios sin anotación **no son negativos**. Un detector entrenado con esa suposición aprendería a no detectar.

3. Reservar los 40 estudios con caja y segmentación como recurso de verificación. Son el único subconjunto que permite comprobar de forma independiente que las máscaras NIfTI están alineadas con los volúmenes DICOM. Conviene usarlos para validar el pipeline geométrico antes que como muestra de evaluación.

4. Fijar el preprocesamiento geométrico antes de cualquier experimento. Ordenar por `ImagePositionPatient[2]`, convertir a HU, remuestrear a 1×1×1 mm y aplicar ventana ósea son decisiones que, mal tomadas, producen resultados silenciosamente incorrectos: no lanzan error, solo degradan el desempeño de forma inexplicable. La validación visual de la superposición máscara-volumen debe ser un paso obligatorio, no opcional.

5. Estratificar por `patient_overall`, por nivel y por `z_extent` discretizado, agrupando por paciente. Es la única forma de que la partición no filtre información entre conjuntos ni deje niveles raros como C3 concentrados en un solo lado.

6. Medir la geometría con la cabecera, no con aritmética sobre el conteo de cortes. La diferencia entre `|z_last - z_first|` y `n_slices × grosor` no es un matiz: cambió el rango aparente del conjunto de 33.7 – 642.6 mm a 48.5 – 334.4 mm, redujo los atípicos de 84 a 29 y debilitó a más de la mitad la asociación con la etiqueta. Cualquier decisión de recorte o remuestreo debe partir de `ImagePositionPatient`, no de un producto.

6.3 Limitaciones de este análisis

- La sección 5.2 conserva las figuras originales del notebook 02, que usan la aproximación `n_slices × slice_thickness`, **junto a** las versiones corregidas con el recorrido físico. Se mantienen ambas de forma deliberada: la comparación es en sí misma el hallazgo metodológico. Las cifras del texto y las conclusiones provienen siempre de la medida corregida.
- Las variables `manufacturer`, `model`, `kernel`, `kvp`, `patient_sex`, `patient_age` y `study_desc` están des-identificadas en este conjunto. El análisis de sesgo por sitio de origen y por demografía, previsto en el diseño, **no puede realizarse** con los datos disponibles.
- Los tres estudios cuyo corte no es 512×512 (dos de 768×768 y uno de 512×519) están incluidos en las estadísticas de área de la sección 5.3 usando 512×512 como denominador. Al ser el 0.15 % del conjunto no altera las medianas, pero sus áreas individuales están mal escaladas.
- Los volúmenes segmentados están expresados en voxeles y no en mm³, por lo que no son directamente comparables entre estudios de distinta resolución.
- Las conclusiones se refieren a los 2 019 estudios de entrenamiento. Los conjuntos de prueba pública (304) y privada (789) no tienen etiquetas visibles y pueden diferir en distribución.

Referencias

1. Lin HM, Colak E, Richards T, et al. The RSNA Cervical Spine Fracture CT Dataset. *Radiology: Artificial Intelligence*. 2023;5(5):e230034. <https://doi.org/10.1148/ryai.230034>
2. Goldberg W, Mueller C, Panacek E, et al. Distribution and patterns of blunt traumatic cervical spine injury. *Annals of Emergency Medicine*. 2001;38(1):17–21.
3. Milby AH, Halpern CH, Guo W, Stein SC. Prevalence of cervical spinal injury in trauma. *Neurosurgical Focus*. 2008;25(5):E10.
4. Fredø HL, Rizvi SAM, Lied B, Rønning P, Helseth E. The epidemiology of traumatic cervical spine fractures: a prospective population study from Norway. *Scandinavian Journal of Trauma, Resuscitation and Emergency Medicine*. 2014;22:78.

5. Minja FJ, Mehta KY, Mian AY. Current Challenges in the Use of Computed Tomography and MR Imaging in Suspected Cervical Spine Trauma. *Neuroimaging Clinics of North America*. 2018;28(3):483–493.
6. Voter AF, Larson ME, Garrett JW, Yu JJ. Diagnostic Accuracy and Failure Mode Analysis of a Deep Learning Algorithm for the Detection of Cervical Spine Fractures. *American Journal of Neuroradiology*. 2021;42(8):1550–1556.